

医学统计学专论

01. 概论



- 省代谢病中西医结合研究所，附一院代谢病临床项目办公室
- 硕士研究生导师
- 教育经历：华南理工大学博士研究生毕业
- 工作经历：BGI Shenzhen, COMP@HKBU, SCM\@HKBU
- 电子邮箱：wangchao\@gdpu.edu.cn
- 学术主页：wangchao.netlify.com
- 研究方向：系统/计算生物学，药物靶向设计，中西医结合临床医学
- 办公室地址：广东药科大学科技楼五楼

课程时间

- 2025/2026学年第一学期（第2周至9周）
- 每周周四
- 晚间，18：00至21：20
- 如遇到节假日或本人通知向后顺延

日	一	二	三	四	五	六
	1 初十	2 十一	3 十二	4 十三	5 十四	6 十五
7 白露	8 十七	9 十八	10 教师节	11 二十	12 廿一	13 廿二
14 廿三	15 廿四	16 廿五	17 廿六	18 廿七	19 廿八	20 全民国防教育日
21 三十	22 八月	23 秋分	24 初三	25 初四	26 初五	27 初六
28 初七	29 初八	30 初九				
九月						

日	一	二	三	四	五	六
			1 国庆节	2 十一	3 十二	4 十三
5 十四	6 中秋	7 十六	8 寒露	9 十八	10 十九	11 二十
12 廿一	13 廿二	14 廿三	15 廿四	16 廿五	17 廿六	18 廿七
19 廿八	20 廿九	21 九月	22 初二	23 霜降	24 初四	25 初五
26 初六	27 初七	28 初八	29 重阳节	30 初十	31 万圣节前夜	
十月						

日	一	二	三	四	五	六
						1 万圣节
2 十三	3 十四	4 十五	5 十六	6 十七	7 立冬	8 十九
9 二十	10 廿一	11 廿二	12 廿三	13 廿四	14 廿五	15 廿六
16 廿七	17 廿八	18 廿九	19 三十	20 十月	21 初二	22 小雪
23 初四	24 初五	25 初六	26 初七	27 感恩节	28 初九	29 初十
30 十一						
十一月						

课程框架

- 01. 概论
- 02. 概率基础
- 03. 统计推断
- 04. 统计图形
- 05. 方差分析
- 06. 回归分析
- 07. 非线性回归
- 08. 多元线性回归

成绩评定


- 日常考核 (30分)
 - 总共三次 (10分每次)
 - 随机在课前或者课后完成
- 期终考试 (70分)
 - 笔试
 - 20~25道单选题 (50分) , 1~2道大题 (20分)
- 闭卷, 以考核课堂内容为主

教学重点

- 重点讲解统计方法在生物医学研究中的应用
- 不强调公式的推导和证明，但是要大概了解计算过程
- 统计学是基于数学的推导，不是死记硬背

Q&A

- 发送邮件: wangchao@gdpu.edu.cn
- 办公室 (周一至周五下午)
- Github Issues



github.com/Solipugids/biostatistics_course_2022.git


学习资源

• 工具

- 办公软件: WPS, Microsoft Excel
- 专业统计软件: GraphPad Prism, Matlab, SPSS
- 编程语言: R, Python

• 参考书籍

- 生物统计学 (第五版), 李春喜, 科学出版社
- 概率论与数理统计 (第五版), 浙江大学, 高等教育出版社
- An Introduction to Statistical Learning, Gareth James
- The elements of statistical learning (Data Mining, Inference, and Prediction), Hastie, Tibshirani and Friedman



RStudio



- R
 - R is 'GNU S', a **freely** available language and environment for statistical computing and graphics which provides a wide variety of statistical and graphical techniques: linear and nonlinear modelling, statistical tests, time series analysis, classification, clustering, etc.
- Rstudio Desktop
 - 基于R开发的统计学工具
 - 在环境配置和可视化上面增加了非常多特性
- Rstudio Server
 - 自建，校内网访问地址 10.91.10.83:8787 (通过发送邮件申请使用权限)
 - 官方 <<https://posit.cloud/>> (自行注册账号使用)

biostatistics_course_2022 - RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

Go to file/function Addins

1.Intro.Rmd

Source Visual

```
41 ~~~
42
43 ## 学习资源
44
45 - 计算语言: ![R](./Rlogo.png){width=5%} $~$ [R](https://www.r-project.org/) & [CRAN](https://cran.r-project.org/)
46
47 > R is 'GNU S', a freely available language and environment for statistical computing and graphics which provides a wide variety of statistical and graphical
48 techniques: linear and nonlinear modelling, statistical tests, time series analysis, classification, clustering, etc.
49
50 - 参考书籍:
51   - 生物统计学 (第五版) · 李春喜
52   - 概率论与数理统计 (第五版)
53
54 ## RStudio
55 - 使用软件: ![RStudio](./rstudio_logo.png){width=10%} RStudio <https://www.rstudio.com/>
56 - RStudio Server:
57   - 中研院 e032-120-85-130-202.ngrok.io (校内网访问地址 10.91.10.250:8787)
58   - 官方 https://rstudio.cloud/ (自行注册账号使用)
59
60 ## DEMO
61
62 ~~~{r echo=FALSE, message=FALSE, tidy=TRUE}
63 print(diamonds[1:2, 1:5])
64 ~~~
65 ~~~{r warning=FALSE, message=FALSE, tidy=FALSE, fig.align='center', fig.height=4, crop=TRUE}
66 ggplot(diamonds, aes(carat, price, colour=cut)) +
67   geom_point(alpha = 1/3) + stat_smooth()
68 ~~~
69 ## 课程考核
70
```

Environment History Connections Git Tutorial

R Global Environment

Data

data	2 obs. of 2 variables
font_files	201 obs. of 6 variables

Values

basedir	"C:\\Users\\WANGCHAO\\AppData\\Roaming\\TinyTeX\\texmf-...
cols	chr [1:4] "#ED1C24" "#228B4C" "#FFC90E" "#3F48CC"
egg	num [1:100] 15 12 13 12 14 10 12 14 15 14 ...
fdt_eg	'table' int [1:9(1d)] 1 2 12 13 29 21 17 3 2
fish	num [1:150] 63 44 47 42 52 29 45 58 62 57 ...
info	num [1:4] 1 2 4 8
names	chr [1:4] "Google" "Runoob" "Taobao" "Weibo"
piepercent	chr [1:4] "7 %" "13 %" "27 %" "53 %"
sp	'table' int [1:9(1d)] 1 2 12 13 29 21 17 3 2

Files Plots Packages Help Viewer Presentation

New Folder New Blank File Delete Rename More

Et > GitHub > biostatistics_course_2022

Name	Size	Modified
..		
.gitignore	110 B	Aug 31, 2022, 3:50 PM
.RData	6.8 KB	Jul 26, 2022, 8:08 PM
.Rhistory	9.6 KB	Aug 22, 2022, 12:24 AM
1.Intro		
2.Data		
3.Probability		
biostatistics_course_2022.Rproj	216 B	Aug 24, 2022, 10:19 AM
LICENSE	1.1 KB	Jul 22, 2022, 11:39 PM
README.md	639 B	Jul 25, 2022, 9:48 PM
Table2_before_matching.csv	353 B	Aug 17, 2022, 12:28 AM

Console Render

```
R 4.2.0 · E:/GitHub/biostatistics_course_2022/
> pnorm(150, p=c(0.02, 0.02, 0.11, 0.18, 0.26, 0.16, 0.11, 0.04, 0.04, 0.04, 0.01, 0.006))
Error in pnorm(150, p = c(0.02, 0.02, 0.11, 0.18, 0.26, 0.16, 0.11, 0.04, :
unused argument (p = c(0.02, 0.02, 0.11, 0.18, 0.26, 0.16, 0.11, 0.04, 0.04, 0.01, 0.006))
> set.seed(2022)
> fish <- round(rnorm(150, mean = 55, sd = 10))
> summary(fish)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 26.00  49.25   57.00   55.77  64.00   84.00
> hist(fish)
> ?rnorm
> set.seed(2022)
> fish <- round(rnorm(150, mean = 55, sd = 10, log.p=TRUE))
Error in rnorm(150, mean = 55, sd = 10, log.p = TRUE) :
unused argument (log.p = TRUE)
> set.seed(2022)
> fish <- round(rnorm(150, mean = 55, sd = 9))
> hist(fish)
> summary(fish)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 29.00  50.00   56.50   55.69  63.00   81.00
> unlink("3.Probability/3.Probability_cache", recursive = TRUE)
>
```

Demo


- diamonds数据集

- diamonds数据集是包括近54000颗钻石的价格和其他属性的内置数据集，共`53940`行条目和`10`个变量
- 每行数据代表一个不同的钻石的属性数据（价格、重量、颜色、透明度等）

```
      carat cut      color clarity depth table price      x      y      z
      <dbl> <ord>    <ord> <ord>    <dbl> <dbl> <int> <dbl> <dbl> <dbl>
1  0.23 Ideal      E      SI2      61.5   55   326  3.95  3.98  2.43
2  0.21 Premium   E      SI1      59.8   61   326  3.89  3.84  2.31
3  0.23 Good      E      VS1      56.9   65   327  4.05  4.07  2.31
4  0.29 Premium   I      VS2      62.4   58   334  4.2   4.23  2.63
5  0.31 Good      J      SI2      63.3   58   335  4.34  4.35  2.75
6  0.24 Very Good J      VVS2      62.8   57   336  3.94  3.96  2.48
7  0.24 Very Good I      VVS1      62.3   57   336  3.95  3.98  2.47
8  0.26 Very Good H      SI1      61.9   55   337  4.07  4.11  2.53
9  0.22 Fair      E      VS2      65.1   61   337  3.87  3.78  2.49
10 0.23 Very Good H      VS1      59.4   61   338  4     4.05  2.39
#> # 53,930 more rows
```


RStudio Demo

- 考察钻石的价格受到哪些因素影响更大
 - x轴：钻石重量（克拉/carat）
 - y轴：价格
 - 不同颜色：钻石切割的质量（cut），分为几个级别，Fair, Good, Very Good, Premium, Ideal
- 统计图形在数据分析的前、中、后期发挥重要的作用



1. 统计学的概念


- 统计学主要研究随机现象的数量规律，是用数理统计的原理和方法来分析和解释生物界各种现象和试验调查资料的科学
- 属于生物数学的范畴，涉及到概率和微积分等知识
 - 概率论：集合（子集，并集，交集……），排列组合
 - 线性代数：函数，导数，微积分
 - 矩阵
- 医学统计学是数理统计在生物医学研究中的应用



T_m : 随温度升高，双链DNA的双螺旋结构发生降解，全部双螺旋结构降解一半的温度称为双链DNA的溶解温度 T_m

1. 统计学的概念


- 随机现象



大气运动



人群



Stochastic Gene Expression in a Single Cell. Michael B. Elowitz et al., Science, 297,1183-1186(2002).

1. 统计学的概念

- 证券市场

- 证券市场的大盘指数在一段时间里，会在一定的价格区间内上下波动，偶尔会短时间超出这个区间（震荡）
- 黑色星期四



2. 统计学的发展

- 统计实践随着计数活动开始（原始社会）
- 上升到理论成为系统的统计学（17世纪英国）
 - 政治算数：Political Arithmetick, 1690, W. Petty.
 - 该书分为两部分：英法荷三国国力比较，英国国情国力和增长分析
- 发展经历三个阶段
 - 古典记录统计学
 - 近代描述统计学
 - 现代推断统计学

2. 统计学的发展


- 古典记录统计学
 - 17世纪中叶-19世纪中叶
 - 初步建立了统计研究的方法和规则
 - 引进概率论，逐渐成为一种较为成熟的方法
 - 伯努利大数定律：在N重伯努利实验（抛硬币）中，在实验次数足够大条件下某一事件发生的频率可无限接近真实发生的概率
 - 拉普拉斯中心极限定理
 - 正态分布理论：高斯



伯努利


2. 统计学的发展

- 古典统计学
 - 大数定律 (law of large numbers) : 通过大量重复实验用事件发生的频率去估计概率



2. 统计学的发展


- 古典统计学
 - 赌场经济学
 - 通过赌场大量玩家参与的赌博事件拉高庄家赢的概率
 - 医学研究领域
 - 小样本可能误导
 - 多中心临床试验的必要性
 - 保险产业应用



2. 统计学的发展

- 古典统计学
 - 中心极限定理 (central limit theorem)

描述独立同分布随机变量（即来源相同、互不影响的样本）的均值或总和的分布规律：当样本数量足够大时，无论单个随机变量本身服从什么分布，这些变量的均值会近似服从正态分布（即“钟形曲线”分布）。



高登板

2. 统计学的发展

- 近代描述统计学
 - 19世纪中叶-20世纪上半叶
 - 统计学应用于生物研究的开始
 - 分析父母辈和子女的变异，探寻遗传规律，应用统计方法研究人种特性和遗传
 - 孟德尔遗传定律，约5,000株豌豆植株
 - 罗纳德·费舍尔：自然选择的遗传理论 The Genetical Theory of Natural Selection, 1930年
 - 中位数、百分位数、四分位数、分布：Galton
 - 相关，回归，卡方检验：Pearson

2. 统计学的发展

- 现代推断统计学
 - 20世纪初至20世纪中叶
 - 各种事物与现象之间繁杂的数量关系以及未知的数量变化，单靠记录或描述的统计方法难以奏效
 - 要求采用推断的方法来掌握事物之间的真正联系，并对事物进行预测
 - t分布和t检验：小样本分布检验的理论和方法，Gosset
 - 方差和方差分析：显著性检验和估计理论，Fisher
 - 统计假设检验学说：Pearson, Newman

- 中国的统计学发展


- 明朝从明太祖朱元璋开始，官方主导编制《大明会典》



显微镜下的大明，马伯庸

史记·夏本纪：

禹会诸侯江南，计功而崩，因葬焉，命曰会稽，会稽者，会计也。



万历会计录

2. 统计学的发展

- 中国的统计学发展
 - 建国前：
 - 1902 年，《钦定京师大学堂章程》规定，在商科大学正式讲授统计学课程
 - 日本社会统计学者横山雅男先生所著的《统计讲义录》被译成中文
 - 顾澄教授翻译了《统计学之理论》
 - 建国后：
 - 学习苏联的统计学建设
 - 变成了一门独立建设的一级学科
 - 引入计算机：SPSS, Excel

3. 医学统计的特殊性

- 小样本（抽样偏倚）
 - 实验医学（成本）
 - 临床医学（伦理）
- 数据分布难以通过正态性检验
 - 正态性不被明确的研究结果推翻的情形下，尽量采用正态性方法，以保证检验功效和结果的可解释性
 - 正态检验
- 数值变量的连续性
 - 除了无序的分类变量外，本质可以认为大部分数据理论上是连续的
 - 对变量的表述不必过于强调其连续与否，可以笼统为数值变量

某学院学生的体测数据, 包含体重(斤)、腰围(码)、1分钟脉搏(次)、引体向上次数、5分钟仰卧起坐次数和1分钟跳绳次数,随机抽取20人, 如表所示。
这是一个容量为20的多维样本。

4. 常用统计术语

- 总体与样本
- 总体：具有相同性质的个体所组成的集合
 - 个体：组成总体的基本单元
 - 无限总体和有限总体
 - 研究总体的困难：个体数目多/试验具有破坏性/试验成本很高
 - 抽样：从总体中抽取一部分个体进行研究
- 样本：从总体中抽出若干个体所构成的集合
 - 样本单位：构成样本的每个个体
 - 样本容量：样本中个体的数目，记为n
 - 从样本中来估计总体 - 小样本(< 30)和大样本 (≥ 30)，注意区别

编号	体重	腰围	脉搏	引体向上	起坐次数	跳跃次数
1	141	33	70	5	162	90
2	139	34	72	2	110	90
3	143	35	78	12	101	131
4	112	32	82	12	105	67
5	139	32	66	13	155	88
6	132	33	76	4	101	72
7	161	35	76	8	101	68
8	117	31	80	6	125	70
9	126	29	94	15	200	70
10	104	30	76	17	251	170
11	119	31	70	17	120	68
12	116	30	72	13	210	145
13	104	31	84	14	215	135
14	167	40	70	1	50	80
15	153	33	66	6	70	61
16	152	34	82	12	210	150
17	126	34	74	4	60	55
18	107	29	72	11	230	110
19	106	33	74	15	225	103
20	108	30	88	2	110	73

4. 常用统计术语

- 抽样
 - 使所抽取的样本能很好地反映总体
 - 最理想的抽样方法是简单随机抽样
 - 满足以下两个要求
 - 随机性：每个个体都有同等的机会被选到样本中
 - 独立性：每个个体的选取并不影响其他个体的选取
 - 抽样的方法依据试验而定

4. 常用统计术语

- 参数与统计数
- 参数：对一个总体特征的度量（常常是未知的）
 - 总体平均数 μ
 - 总体标准差 σ
- 统计数：由样本计算所得的数值，描述样本的特征
 - 样本平均数 $\bar{x}$
 - 样本标准差 s
- 通过抽样，根据样本的统计数来估计总体的参数

4. 常用统计术语

- 变量与资料
- 变量：相同性质的事物间表现差异性的某项特征或性状，是试验指标
 - 资料：变量的观察结果，也称为变量值
 - 定量变量
 - 连续型变量
 - 离散型变量，通常是整数 -
 - 定性变量
 - 变量的类型根据研究目的确定，各类变量可以相互转化
- 常量：代表事物特征和性质的数值，通常由变量计算而来，一定过程中一般是不变的
 - 自然对数 e ，圆周率 π
 - 总体平均数、标准差、变异系数

4. 常用统计术语

- 因素与水平
 - 因素：试验中所研究的影响试验指标的原因或原因组合
 - 抽象的概念
 - 水平：每个试验因素的不同状态
 - 较为具体的概念
 - 可控因素（人为调控）/非控因素（随机产生）

4. 常用统计术语

- 处理与重复
 - 处理：对受试对象（试验单位）给予的某种外部干预
 - 单因素处理：试验中涉及的因素只有一个
 - 多因素处理：试验中涉及两个或两个以上的因素
 - 研究因素的主效
 - 研究因素之间的交互作用-
 - 重复：在试验中，将一个处理实施在两个或两个以上的试验单位上
 - 处理实施的试验单位数即为重复数

4. 常用统计术语

- 效应与互作
- 效应/主效：试验因素相对独立的作用
- 互作效应：两个或两个以上处理因素间相互作用所产生的效应（正效应/负效应）
 - 氮磷肥共施对作用产量产生交互作用

4. 常用统计术语

- 精确性与准确性
 - 准确性：调查或试验中某一试验指标或性状的观测值与真值接近的程度 -
 - 反映测定值与真值符合程度的大小-
 - 精确性：调查或试验中同一试验指标或性状的重复观测值彼此接近程度的大小 -
 - 反映多次测定值的变异程度-
- 准确性不等于精确性

4. 常用统计术语

- 误差和错误
- 误差：也称为试验误差，是指观测值偏离真值的差异，分为随机误差和系统误差
 - 随机误差：由于试验中许多无法控制的偶然因素所造成的试验结果与真实值之间的差异，是不可避免的
 - 系统误差：由于试验处理以外的其他条件明显不一致所产生的带有倾向性的或定向性的偏差
- 错误：在实验过程中，人为因素引起的差错

5. 资料特征数的计算

- 平均值

- 算数平均数(Arithmetic mean)

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

- 中位数

- 众数

- 几何平均数(Geometric mean)

$$G = \sqrt[n]{x_1 x_2 x_3 x_3 x_5}$$

5. 资料特征数的计算

- 变异数
 - 极差：最大值和最小值之差
 - 方差

$$s^2 = \frac{\sum(x - \mu)^2}{N}$$

- 标准差

$$s = \sqrt{\frac{\sum(x - \mu)^2}{N}} = \sqrt{s^2}$$

5. 资料特征数的计算

- 变异数
 - 变异系数：
 - 标准差和算数平均数的比值，
 - 相对变异量
 - 无单位
 - 使用变异系数可以比较不同样本相对变异程度的大小

$$CV = \frac{s}{\bar{x}} \times 100\%$$

不同收入群体收入稳定性：

群体 A（普通收入）：月收入均值 5000 元，标准差 500 元

群体 B（高收入）：月收入均值 50000 元，标准差 5000 元

若直接看标准差：5000 元（B）>500 元（A），似乎 B 的收入波动更大

计算变异系数：

$$CV(A) = 500/5000 = 10\%$$

$$CV(B) = 5000/50000 = 10\%$$

所以两个群体波动相似，不存在高收入群体波动更大的问题

5. 资料特征数的计算

- 自由度
- 数据独立变化的自由程度
- X_i 对 $\bar{X}$ 的偏差 $X_i - \bar{X}$ 可正可负，其和恒为零，即

$$\sum_{i=1}^n (X_i - \bar{X}) = 0$$

- 这表明 n 个偏差中只有 $n - 1$ 个是独立的
- 在统计中独立偏差的个数称为**自由度**，记为 f ，故 n 个偏差共有 $n - 1$ 个自由度，即 $f = n - 1$

思考题

- 下面变量中属于非连续变量的是____（单选题）
 - A、血糖含量
 - B、血型
 - C、血脂含量
 - D、血压

谢谢

