

医学统计学专论

02. 概率和概率分布



- 概率和概率分布

1. 事件和概率

2. 概率计算

3. 概率分布

- 概率论和统计学的关系
 - 概率论主要研究随机现象的规律性，也就是通过已知的概率分布来推断样本
 - 统计学则是通过样本数据来推断总体的性质



是什么?

已知一个箱子里有多少红球和绿球，
概率论可以计算下一个摸出来的球是红/绿球的概率

总体（箱子）


样本（取球）

面对黑箱子只能看到每次取出来的是红球还是绿球
统计学需要猜测红/绿球的比例

怎么办?


- 概率论和统计学的关系
 - 概率论是统计学的基础，统计学是概率论的应用
 - 统计学通过样本数据来估计总体的概率分布，而概率论则解释为什么这些估计是合理的
 - 方法学上
 - 概率论：大数定理和中心极限定理保证统计推断的合理性
 - 统计学：运用**参数估计**、**假设检验**进行估计

- 参数估计
 - 基于样本，推断总体的参数（均值&方差），并量化估计的不确定性
 - 台风路径的预测
 - 台风预测实际是对一个随机变量的参数估计问题
 - 随机变量：台风在未来某一时刻的“实际位置”
 - 阴影区域：随机变量的参数估计置信域，或者说是路径的大概率覆盖区间




• 参数估计

- 台风运动是受到多种复杂因素影响的随机过程，并非确定性轨迹
- 总体：台风在未来某一时刻（如 24 小时后、48 小时后）的“所有可能位置”构成的集合
- 样本：用于估计上述参数的“观测数据”
 - 台风当前的位置、强度、移动速度
 - 历史数据
 - 大气环境
 - 不同预报方法输出的多组模拟结果
- 置信区间：包含真实参数的大概率区间（或区域）




- 当获得一个可能的台风路径之后，广州位于台风路径上的可能性有多少



1. 概率的概念

- 事件
- 在一定条件下，某种事物出现与否被称为是**事件 (event)**
 - 确定事件：
 - 必然事件 U ：在一定条件下必然出现的现象， Ω
 - 不可能事件 V ：在一定条件下必然不出现的事件， $\emptyset$
 - 随机事件：
 - 有可能发生，也可能不发生



1. 概率的概念

- 频率
- 在 n 次试验中，事件 A 出现的次数 m 称为事件 A 出现的**频数**，比值 $\frac{m}{n}$ 称为事件 A 出现的**频率**，记作 **$W(A)$**
- $W(A) = m/n, 0 \leq W(A) \leq 1$

为测定某批玉米种子的发芽率，分别取 10, 20, 50, 100, 200, 500, 1000 粒种子。在相同条件下进行发芽试验：

种子总数n	发芽m	种子发芽率W(A)
10	9	0.9
20	19	0.95
50	47	0.94
100	91	0.91
200	186	0.93
500	459	0.918
1000	920	0.92


1. 概率的概念

- 假设在相同的条件下，进行大量重复试验，若事件 A 的频率稳定地在某一确定值 p 的附近摆动，则称 p 为事件 A 出现的概率，记作 $P(A)$
- $P(A) = p = \lim_{n \rightarrow \infty} \frac{m}{n}, 0 \leq P(A) \leq 1$
- 不可能完全准确得到 p ，在 n 充分大时，频率 $W(A)$ 作为 $P(A)$ 的近似值
- 概率的基本性质：
 - 任何事件的概率都在 0 和 1 之间，也就是 $0 \leq P(A) \leq 1$
 - 必然事件的概率等于 1 $P(U) = 1$
 - 不可能事件的概率等于 0 $P(V) = 0$

1. 概率的概念

- 当 n 足够大的时候, 为什么可以用样本中的 $W(A)$ 代替 $P(A)$?
- 样本容量越大, 样本的统计数与总体参数之差越小
- 大数定律是用来阐述大量随机现象的平均结果稳定性的一系列定律
 - 伯努利大数定律 (特殊的二元非0即1的实验, 例如掷硬币)
 - 辛钦大数定律 (一般性实验, 多结果, 例如掷色子)

辛钦大数定律: 样本均值收敛到期望值



1. 概率的概念

- 伯努利大数定律
 - m 是 n 次独立试验中事件 A 出现的次数, p 是事件 A 在每次试验中出现的概率, 对于任意小的正数 ϵ , 有:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{m}{n} - p\right| < \epsilon\right) = 1$$

- 辛钦大数定律

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{\sum_{i=1}^n x_i}{n} - \mu\right| < \epsilon\right) = 1$$

- 设一个随机变量 x_i , 是由一个总体平均数 μ 和随机误差 ϵ 构成 $x_i = \mu + \epsilon_i$
- 如果随机抽出 n 个, 那么样本的平均数等于

$$\bar{x} = \sum (\mu + \epsilon_i) / n = \mu + \frac{1}{n} \sum_i \epsilon$$


- 样本容量越大, 样本统计数与总体参数之差越小

2. 概率的计算

- 集合论
 - 集合论为概率提供了严格的数学语言，是概率的语言系统
 - 很多概率公式（如容斥原理、全概率公式、贝叶斯公式），本质上都是集合运算的直接翻译
- 用集合论可以来描述 “事件” 和 “样本空间”：
 - 样本空间 Ω ：所有可能结果组成的 “全集”（必然事件）
 - 事件 A ： Ω 的一个子集（某个结果集合）
 - 不可能事件：空集 $\emptyset$
- 事件的关系：
 - 包含： $A \subseteq B$ （ A 发生则 B 必然发生）
 - 并集： $A \cup B$ （ A 或 B 至少一个发生）
 - 交集： $A \cap B$ （ A 和 B 同时发生）
 - 补集： A^c （ A 不发生）

2. 概率的计算


- 事件的关系：“和”事件
 - 事件 A 和事件 B 至少有一件发生而构成的新事件



维恩图, Venn diagram


2. 概率的计算

- 事件的关系：“积”事件
 - 事件 A 和事件 B 同时发生而构成的新事件




2. 概率的计算

- 事件的关系：“积”事件的特例互斥事件
 - 事件 A 和事件 B 不可能同时发生




2. 概率的计算

- 事件的关系：互斥事件的特例对立事件
 - 事件 A 和事件 B 不可能同时发生，但是必然有一个发生
 - 例如：新生儿要么为男孩，要么为女孩



2. 概率的计算

- 事件的关系
- 独立事件
 - 事件 A 的发生与事件 B 的发生毫无关系
 - 独立事件群：多个事件 $A_1, A_2, A_3, \dots, A_n$ 彼此独立
 - 完全事件：多个事件 $A_1, A_2, A_3, \dots, A_n$ 两两相斥，且每次试验结果必然发生其一
- 条件概率
 - 当 A 发生时，B 发生的概率，记作 $P(B|A)$



2. 概率的计算

集合关系 / 运算	概率公式	含义
并集	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	A 或 B 至少一个发生
互斥事件	$P(A \cup B) = P(A) + P(B)$ (当 $A \cap B = \emptyset$)	A、B 不能同时发生
补集	$P(A^c) = 1 - P(A)$	A 不发生的概率
条件概率	$P(A B) = \frac{P(A \cap B)}{P(B)}$	B 已发生时 A 发生的概率
独立事件	$P(A \cap B) = P(A)P(B)$	A 发生与否不影响 B

2. 概率的计算

- 概率计算法则
- 乘法定理
- 如果事件 A 和事件 B 为独立事件，则事件 A 与事件 B 同时发生的概率等于事件 A 和事件 B 各自概率的乘积，称为乘法定理

$$P(A \cap B) = P(A) \cdot P(B)$$

- 推理：如果 $A_1, A_2, A_3, \dots, A_n$ 彼此独立（独立事件群），则

$$P(A_1 \cdot A_2 \cdot \dots \cdot A_n) = P(A_1) \cdot P(A_2) \cdot \dots \cdot P(A_n)$$

- 如果是非独立事件，则 $P(A \cap B) = P(A) \cdot P(B|A)$

2. 概率的计算

- 概率计算法则
- 加法定理
- 互斥事件A 和 B 的和事件的概率等于事件 A 和事件 B 的概率之和，称为加法定理

$$P(A \cup B) = P(A) + P(B)$$

- 推理1：如果 $A_1, A_2, A_3, \dots, A_n$ 彼此独立（独立事件群），则

$$P(A_1 \cdot A_2 \cdot \dots \cdot A_n) = P(A_1) \cdot P(A_2) \cdot \dots \cdot P(A_n)$$

- 推理2：对立事件 $\bar{A}$ 的概率为

$$P(\bar{A}) = 1 - P(A)$$

- 推理3：完全事件系和事件的概率等于 1
- 如果事件 A 和 B 不互斥，那需要减去两个事件的交集

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

2. 概率的计算

- 概率计算法则
- 贝叶斯定理
- 事件 A 在事件 B 发生的条件下与事件 B 在事件 A 发生的条件下，它们两者的概率并不相同，但是它们两者之间存在一定的相关性, 并具有以下关系

$$P(A|B) = P(B|A)P(A) / P(B)$$

- 推导过程：

$$P(A \cap B) = P(B \cap A)$$

$$P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

$$P(A|B) = P(B|A)P(A) / P(B)$$

2. 概率的计算

- 贝叶斯学派和频率学派
- **频率学派**
 - 概率是长期重复试验中事件发生的频率极限
 - 概率是客观存在，不依赖主观判断
 - 总体的参数是固定的未知常数，通过抽样估计
- 贝叶斯学派
 - 概率是主观信念的程度，反映对事件的相信程度
 - 用先验概率表达初始的信念
 - 参数为随机变量，有概率分布

2. 概率的计算

- 贝叶斯学派和频率学派
- **频率学派**
 - 概率是长期重复试验中事件发生的频率极限
 - 概率是客观存在，不依赖主观判断
 - 总体的参数是固定的未知常数，通过抽样估计
- 贝叶斯学派
 - 概率是主观信念的程度，反映对事件的相信程度
 - 用先验概率表达初始的信念
 - 参数为随机变量，有概率分布

已知某种疾病在人群中的发病率（先验概率）为 1%，某检测方法对该疾病的真阳性率（即患病者被检测为阳性的概率）为 99%，真阴性率（即非患病者被检测为阴性的概率）为 95%。当一个人检测结果为阳性时，根据贝叶斯定理计算其实际患病的后验概率：

$$P(A|B) = P(B|A)P(A) / P(B)$$

$$P(\text{阳性} | \text{患病}) = 0.99$$

$$P(\text{患病}) = 0.01$$

$$P(\text{阴性} | \text{非患病}) = 0.95$$

$$P(\text{阳性}) = ?$$

假设诊断阳性为事件B，患病为事件A

$$P(\text{患病} | \text{阳性}) = ?$$

3. 概率分布

- 研究随机变量数据，主要是研究变量的取值范围，也就是取值的概率
- 概率分布：随机变量的取值与取这些值的概率之间的对应关系
- 这种对应关系可以函数化，用分布函数来进行表述
- 两种类型变量对应不同的分布：
 - 离散型变量
 - 二项分布
 - 泊松分布
 - 连续型变量
 - 正态分布


3. 概率分布

- **离散型变量**/非连续变量：在变量数列中仅能取得固定数值，通常是整数
- 例如年龄或者年份，0岁到100岁，2000年到2025年
- 年龄段或者时间段就是离散型变量 x ，每一段记为 x_i
- 对于任意 x_i ，都有对应时间段下的结核病的发生率 p_i
- 可以如下方式表示：

$$P(x = x_i) = p_i, (i = 1, 2, 3, 4, 5 \dots n)$$

所以，

$$\sum p_i = 1$$




3. 概率分布

- **连续型变量**：变量之间是连续的、无限的，任意范围都可以进行取值
- 对连续型随机变量的次数分布表作直方图，直方图中同一间距内的频率密度是相等的
- 如果从总体中抽取样本的容量 n 相当大，则频率分布就趋于稳定，近似地看成总体的概率分布
- 当 n 无限大，频率转化为概率，频率密度转化为概率密度，直方图逼近光滑连续曲线
 - 概率密度曲线（曲线下的总面积为 1）
 - 存在一个概率密度函数 $f(x)$
 - R示例

3. 概率分布

- 连续型随机变量的概率分布
- R示例



对于一个连续型变量 x ，取值于区间内的概率即黄色阴影部分的面积，也就是概率密度函数 $f(x)$ 的积分，即

$$P(x_1 \leq x \leq x_2) = \int_{x_1}^{x_2} f(x) dx$$

3. 概率分布

- 二项分布的概率函数
- 二项分布是一种离散型随机变量的分布
- 每次试验只有两个对立结果，A 和 $\bar{A}$ ，出现的概率分别记为 p 和 q ($q = 1 - p$)
- 实验结果具有独立性和重复性
 - 独立性：任何一次试验中事件 A 的出现与其余各次试验中出现的任何结果无关
 - 重复性：每次试验条件不变，在每次试验中事件 A 出现的概率都是 p
- 二项分布可以记为 $B(n, p)$ ，概率分布函数为
$$P(x) = C_n^x p^x q^{(n-x)}$$
- B代表Binomial，组合数是因为 $C(n,x)$ 需要考虑“哪x次成功”和“成功 / 失败的概率”
- 试验次数n，事件A出现的概率为p


抛 5 次硬币，恰好 2 次正面 ($p=0.5$)，
那么有 $C(5,2)=10$ 种可能：

HHTTT
HTHTT
HTTHT
HTTTH
THHTT
THTHT
THTTH
TTHHT
TTHTH
TTTHH

每种发生的概率 每种的概率
 $0.5^2 \cdot 0.5^3 = 0.5^5 = 1/32$
总概率需要考虑所有的种类

3. 概率分布

- 二项分布的概率函数
- 二项分布的形状由 n 和 p 两个参数决定
- n 值不同的情况下, p 值较小的时候, 分布是偏倚的
- p 值趋于 0.5 的时候, 分布趋于对称



3. 概率分布

- 二项分布的概率函数
- 二项分布中的参数
 - 平均数

$$\mu = np$$

- 标准差

$$\sigma = \sqrt{npq} = \sqrt{np(1 - p)}$$


3. 概率分布

- 泊松分布的概率函数
- 当n很大，p很小的时候，二项分布就趋向于泊松分布
- 泊松分布的概率密度分布函数可以从二项分布推导近似得到


$$P(x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

- λ 是参数， $\lambda = np$ ；e 为自然对数，x 为正整数

约 50 个菌落



约 200 个菌落



例如：

- ✓ 细菌菌落计数在理想条件下确实符合泊松分布
- ✓ 荧光显微镜中光子计数型探测器记录的信号服从泊松分布
- ✓ DNA 测序中的read数符合泊松分布

细菌均匀分散在稀释液中
每个细菌独立生长成一个菌落
菌落不重叠（没有融合）
计数区域足够大，但菌落密度不太高


3. 概率分布

- 泊松分布的概率函数
- 分布函数形状由 λ 决定
- 平均数

$$\mu = \lambda$$

- 标准差

$$\sigma = \sqrt{\lambda}$$



3. 概率分布

- 正态分布
- 多数变量都围绕在平均值左右，由平均值到分布的两侧，变量数逐渐减少
- 在统计理论和应用上最重要的分布
 - 试验误差的分布一般都服从于这种分布
 - 许多生物现象的计量资料也服从于这种分布
 - 正态分布还可作为离散型随机变量或其他变量的近似分布（中心极限定理）

3. 概率分布

- 正态分布
- 正态分布的概率密度函数根据二项分布的函数在 $n \rightarrow \infty$ 时推导出


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 其中
 - μ : 均值 (位置参数)
 - σ : 标准差 (尺度参数)
 - $x \in (-\infty, \infty)$
- 标准正态分布 ($\mu = 0, \sigma = 1$)

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x)^2}{2}}$$

3. 概率分布

- 正态分布
- 记为 $N(\mu, \sigma^2)$, 表示平均数为 μ , 标准差为 σ 的分布




标准正态分布

- 当 $x = \mu$ 时, $f(x)$ 有最大值
- 当 $x - \mu$ 的绝对值相等, $f(x)$ 值也相等
- $(x - \mu) / \sigma$ 的绝对值越大, $f(x)$ 的值越小, 逼近但不等于 0
- 正态分布曲线完全由参数 μ 和 σ 决定
- 正态分布在 $x = \mu \pm \sigma$ 处各有一个拐点
- 正态分布曲线在 $x \in (-\infty, \infty)$ 皆能取值 (x 取值的完全事件系)


3. 概率分布

- 正态分布

$\sigma = 0.5 \text{ or } 1 \text{ or } 2$



$\mu = -1 \text{ or } 0 \text{ or } 1$




3. 概率分布


- 正态分布
- 一般正态分布如何转换成标准正态分布
- 对于任何一个服从 $N(\mu, \sigma)$ 的随机变量，都可以通过 u 转换进行标准化变换

$$u = \frac{x - \mu}{\sigma}$$

- u 为**标准正态离差**，表示离开平均数 μ 几个标准差 σ
- 作用：
 - 统一比较不同正态分布（非标准正态分布也可以通过查表获得概率）
 - 假设检验和置信区间
 - 方便计算概率



$$u = (x - \mu) / \sigma$$



谢谢

