

医学统计学专论



04. 统计图形 Statistical Graphics



- 对样本所属总体提出无效假设 和备择假设 （ H_0 , H_1)
- 确定检验的显著水平 α (0.05或者0.01)
- 在 H_0 正确的前提下，计算抽样分布的统计数或相应的概率值

$$u = \frac{\bar{x} - \mu}{\sigma_x} = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

- 根据小概率原理，进行差异是否显著的判断并得出结论



随堂测验

$$u = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}} = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

- 某药企声称：其新研发的降压药能使高血压患者的收缩压平均下降 20mmHg，已知降压效果的标准差 $\sigma=5\text{mmHg}$ （基于前期临床试验数据）。
- 为验证该声明，选取 36 名高血压患者进行用药试验，服药后测得样本平均收缩压下降值为 18.5mmHg。
- 若设定显著性水平 $\alpha=0.05$ ，能否认为该降压药的实际效果与药企声明不符？（提示：收缩压下降值服从正态分布）

- 统计图形
 - ✓ 统计表格
 - ✓ 统计图形
 - ✓ 统计图形的起源
 - ✓ 现代统计图形

1. 统计表格

- 表格用来表达统计分析结果中数据和统计指标的表格形式
- 用**简明**的表格形式，有条理地罗列数据和统计量，方便阅读、比较和计算
- 制表原则：
 - 重点突出
 - 层次清楚

1. 统计表格

- 基本要求
- 标题

- 概括表的主要内容，包括研究的时间、地点和研究内容，放在表的上方
- 标目
 - 分别用**横标目**和**纵标目**，说明表格每行和每列数字的意义，注意标明指标的**单位**

Table 1. Characteristic of Participants by Gender and Case-Control Status

Variable*	Male (n=474)	
	Case (n=226)	Control (n=248)
Age, years	69.6 (8.0)	68.7 (7.0)
Body mass index, kg/m ²	22.9 (2.7)	23.1 (3.0)
Primary school education, n (%)	104 (46%)	88 (35.5%)
Hypertension, n (%)	119 (52.7%)	71 (28.6%)
Hyperlipidemia, n (%)	51 (22.6%)	23 (9.3%)

1. 统计表格

- 基本要求

- 线条

- 至少用三条线

- 表格的顶线和底线将表格与文章的其他部分分隔开来

- 纵标目下横线将标目的文字区与表格的数字区分隔开来

- 部分表格可再用横线将合计分隔开，或用横线将两重纵标目分割开

- 其它竖线和斜线一概省去

Table 2 Comparison results of different networks on PH2 and ISIC2018 datasets

Method	PH2				ISIC2018				Para/M	Time/s
	Acc/%	Dice/%	mIoU/%	Kappa/%	Acc/%	Dice/%	mIoU/%	Kappa/%		
U-Net	93.00	92.17	87.30	86.33	93.15	91.62	86.44	85.25	13.40	352
Attention U-Net	93.15	92.30	87.54	86.61	93.28	91.75	86.65	85.49	34.89	536
U ² Net	93.72	92.90	86.83	85.80	94.53	93.11	87.26	86.21	44.05	384
MAU-Net	94.18	93.40	87.70	86.80	94.62	93.21	87.45	86.43	42.02	456
SETR	94.59	94.43	88.64	87.62	95.13	93.85	88.54	87.70	306.96	809
SegFormer	94.21	93.29	88.25	87.28	95.08	93.84	88.51	87.67	84.59	680
MsF-SegFormer	94.72	94.09	88.91	88.20	95.39	94.28	89.29	88.56	83.16	637

CSDN @www1796140

1. 统计表格

- 基本要求
- 数字
 - 用阿拉伯数字表示
 - 无数字用 “—” 表示
 - 缺失数字用NA, n.a.表示
 - 数值为0者记为 “0”
 - 不要留空项
 - 数字按小数位对齐

Exome-chip (n=79,854)		Combined (n=92,794)	
P	OR (95% CI)	P	OR (95% CI)
4.8 × 10 ⁻⁹	1.07 (1.04–1.11)	1.2 × 10 ⁻⁹	1.07 (1.04–1.10)
1.8 × 10 ⁻⁷	1.10 (1.06–1.14)	4.2 × 10 ⁻⁸	1.11 (1.07–1.15)
1.7 × 10 ⁻⁷	1.15 (1.08–1.23)	5.7 × 10 ⁻¹⁰	1.17 (1.11–1.24)
1.0 × 10 ⁻⁶	1.17 (1.10–1.25)	3.3 × 10 ⁻⁸	1.19 (1.12–1.26)
2.7 × 10 ⁻¹⁸	1.14 (1.11–1.17)	4.8 × 10 ⁻²³	1.14 (1.11–1.17)
3.4 × 10 ⁻⁹	1.07 (1.04–1.11)	1.3 × 10 ⁻⁹	1.07 (1.05–1.10)
5.1 × 10 ⁻⁹	1.07 (1.04–1.11)	9.0 × 10 ⁻¹⁰	1.07 (1.05–1.10)
2.3 × 10 ⁻⁸	1.07 (1.04–1.11)	1.7 × 10 ⁻⁸	1.07 (1.04–1.10)
3.5 × 10 ⁻⁸	1.11 (1.07–1.16)	3.3 × 10 ⁻¹⁰	1.12 (1.07–1.16)
4.7 × 10 ⁻¹¹	1.14 (1.10–1.19)	8.3 × 10 ⁻¹⁵	1.15 (1.11–1.19)
9.3 × 10 ⁻¹²	1.08 (1.04–1.12)	9.0 × 10 ⁻¹⁴	1.09 (1.06–1.12)
2.0 × 10 ⁻¹²	1.08 (1.05–1.11)	1.5 × 10 ⁻¹⁴	1.08 (1.05–1.11)
1.3 × 10 ⁻¹⁰	1.07 (1.03–1.10)	6.9 × 10 ⁻¹¹	1.06 (1.04–1.09)
1.1 × 10 ⁻⁵	1.12 (1.06–1.17)	4.0 × 10 ⁻⁹	1.13 (1.09–1.18)
NA	NA	9.3 × 10 ⁻⁹	1.79 (1.47–2.19)
1.7 × 10 ⁻⁹	1.09 (1.06–1.12)	1.7 × 10 ⁻⁹	1.09 (1.06–1.12)
1.9 × 10 ⁻⁷	1.13 (1.08–1.18)	3.2 × 10 ⁻¹⁰	1.14 (1.10–1.19)

1. 统计表格

- 基本要求
- 备注
 - 表中数字区不要插入文字，也不列备注项
 - 必须说明者标 “*” 号，在表下方说明

GPSM1*	GPSM1*	rs60980157 Ser391Leu	0.26	0.26	C, T	NA	NA	1.7 × 10 ⁻⁹	1.09 (1.06–1.12)
CILP2	TM6SF2	rs58542926 Glu167Lys	0.03–0.10	0.082	T, C	0.00015	1.22 (1.10–1.36)	1.9 × 10 ⁻⁷	1.13 (1.08–1.18)
Coding variant associations outside established common variant GWAS regions									
MTMR3/b ASCC2	MTMR3	rs41278853 Asn960Ser	0.92–1.00	0.083	A, G	9.2 × 10 ⁻⁵	1.26 (1.12–1.42)	3.2 × 10 ⁻⁶	1.13 (1.07–1.19)
	ASCC2	rs11549795 Val123Ile	0.92–1.00	0.083	C, T	0.00040	1.23 (1.10–1.38)	2.0 × 10 ⁻⁵	1.13 (1.06–1.20)
		rs28265 Asp407His	0.92–1.00	0.083	C, G	0.00050	1.21 (1.08–1.36)	1.9 × 10 ⁻⁵	1.13 (1.06–1.20)
		rs36571 Pro423Ser	0.92–1.00	0.083	G, A	0.0023	1.23 (1.08–1.40)	2.0 × 10 ⁻⁵	1.13 (1.06–1.20)

These loci were identified through single-variant analyses of exome sequence data from 6,504 cases and 6,436 controls and exome arrays from 28,305 individuals. Eur MAF, minor allele frequency in Europeans; OR, odds ratio; CI, confidence interval; n, total number of individuals analysed. Genome-wide significance (P = 1.0 × 10⁻⁸) in the combined analysis. Three variants at ASCC2 did not achieve genome-wide significance themselves, but with an other significant association signal. Alleles are aligned to the forward strand of NCBI Build 37 and represented as risk and other alleles.

1. 统计表格

- 统计表格的种类

- a) 简单表

- 统计表的主语只有一个层次

- b) 组合表

- 统计表的主语有两个以上层次

1. 统计表格

- 统计表格的种类

1. 简单表

- 统计表的主语只有一个层次
- 上表只有试验分组一个层次，属简单表

Table 1 This table counts the number of features in the data before and after processing

	Raw	Complete	Summarized
Metabolites	8848 clusters	1692 clusters	143 classes
Bacteria	201 species	191 species	51 genera

Removal of features with mostly zeros reduced the number of metabolite clusters from 8848 to 1692, and the number of bacteria species from 201 to 191. Summarization further reduced the dimensionality to 143 classes and 51 genera

Extended Data Table 1 | Most significant single-variant associations from exome-sequencing analysis

外显子组测序分析中最显著的单变异关联

Gene	Variant	Consequence	Impact	Change	MAF	Case	Ctrl	OR	P	Ref	Ref P
PAX4	rs2233580	missense_variant	Med.	p.Arg192His	0.12	890	563	1.7	7.6e-22	[6]	1.8e-12
SLC30A8	rs13266634	missense_variant	Med.	p.Arg325Trp	0.43	12258	13756	0.897	3.4e-11	[6]	1.8e-47
WFS1	rs1801212	missense_variant	Med.	p.Val333Ile	0.27	7101	8456	1.13	1.2e-10	[6]	1.1e-24
KCNJ11	rs5219	missense_variant	Med.	p.Lys23Glu	0.39	16471	15959	0.898	1.2e-10	[6]	5.7e-22
KCNJ11	rs5215	missense_variant	Med.	p.Val250Ile	0.39	16687	16132	0.901	3.4e-10	[6]	4.5e-21
SLC16A11	rs2292351	5_prime_UTR_variant	Low	-	0.34	5244	4249	1.25	1.3e-09	[80]	0.26
SLC16A11	rs13342692	missense_variant	Med.	p.Asp127Gly	0.34	9468	7492	1.12	1.7e-09	[6]	5.7e-05
SLC16A11	rs75493593	missense_variant	Med.	p.Pro443Thr	0.3	6262	4929	1.24	3.2e-09	[80]	0.24
WFS1	rs1801213	synonymous_variant	Low	p.Arg228Arg	0.33	10641	11689	1.1	3.7e-09	[80]	1.e-10
SLC16A13	rs76070643	synonymous_variant	Low	p.Tyr166Tyr	0.3	6357	5028	1.2	1.8e-08	[80]	0.29
WFS1	rs1046317	3_prime_UTR_variant	Mod.	-	0.32	9957	11005	1.09	2.0e-08	[13]	1.3e-09

1. 统计表格

- 统计表格的种类

2. 组合表

是否能直接看出其中数据差异的主要特征

某年某地城乡各年龄组居民乙型肝炎病毒抗原携带率分析

年龄组	城市			乡村		
	检查数	阳性数	阳性率(‰)	检查数	阳性数	阳性率(‰)
<20	42384	274	6.46	9854	49	4.97
20~	228076	2018	8.85	13874	124	8.94
25~	235879	2697	11.43	8414	134	15.93
30~	146142	2093	14.32	5690	90	15.82
35~	74629	1299	17.41	3950	81	20.51
≥40	21193	273	12.88	1499	31	20.68
合计	748303	8654	11.56	43281	509	11.76

1. 统计表格

- 统计表格的种类

2. 组合表

不同心理分值的冠心病危险因素水平比较

危险 因素	心理分值								P 值
	1(252 人)		2(253 人)		3(252 人)		4(253 人)		
	$\bar{X} \pm S$	%	$\bar{X} \pm S$	%	$\bar{X} \pm S$	%	$\bar{X} \pm S$	%	
年龄(岁)	35.2±6.5		37.0±6.3		36.5±6.8		37.8±6.5		<0.05
收缩压(mmHg)	120.7±13.4		121.2±13.2		121.1±13.2		120.4±12.8		<0.5
舒张压(mmHg)	78.8±10.2		77.9±10.5		78.2±11.0		78.4±10.6		<0.39
体力活动	2.1±0.2		2.1±0.1		2.1±0.2		2.3±0.3		<0.08
体重指数	23.1±3.2		24.0±3.5		24.8±3.1		25.8±3.1		<0.01
吸烟率(%)		70.8		69.4		70.7		71.1	<0.41
吸烟量(支/天)	8±1		10±2		15±2		15±2		<0.001
饮酒率(%)		52.3		55.5		53.1		52.8	<0.13
饮酒量(克/天)	60.1±7.5		78.2±8.5		79.3±6.8		106.8±10.2		<0.001
受教育程度	4.5±0.8		4.2±0.9		3.5±0.8		3.4±0.8		<0.05
社会支持	8.7±1.2		7.5±1.1		7.0±1.2		7.0±1.2		<0.05
慢性疾患数构成(%)									
0		81.6		79.3		77.5		73.9	<0.18
1		15.1		16.2		16.5		15.0	<0.43
≥2		3.3		4.5		6.0		11.1	<0.05

1. 统计表格

- 统计表格的种类

2. 组合表

- 将太多的内容放在一个表里，特别是将两种不同类型资料（计量资料和计数资料）的统计量放在同一表中
- 互不相容的内容分别占了不同的列，导致表中有许多空格
- 纵横标目倒置
- 内容较多，层次复杂，表格中数据罗列无条理，较难读懂

1. 统计表格

- 统计表格的种类

2. 组合表

心理 分值	例数	年龄 (岁)	收缩压 (mmHg)	舒张压 (mmHg)	体力 活动	体重指数	吸烟量 (支/天)	饮酒量 (克/天)	受教育 程度	社会支持
1	252	35.2±6.5	120.7±13.4	78.8±10.2	2.1±0.2	23.1±3.2	8±1	60.1±7.5	4.5±0.8	8.7±1.2
2	253	37.0±6.3	121.2±13.2	77.9±10.5	2.1±0.1	24.0±3.5	10±2	78.2±8.5	4.2±0.9	7.5±1.1
3	252	36.5±6.8	121.1±13.2	78.2±11.0	2.1±0.2	24.8±3.1	15±2	79.3±6.8	3.5±0.8	7.0±1.2
4	253	37.8±6.5	120.4±12.8	78.4±10.6	2.3±0.3	25.8±3.1	15±2	106.8±10.2	3.4±0.8	7.0±1.2
P 值	-	<0.05	0.5	0.39	0.08	<0.01	<0.001	<0.001	<0.05	<0.05

某年某地居民不同心理分值的冠心病危险因素水平比较(X±S)

1. 统计表格

- 统计表格的种类

2. 组合表

心理 分值	例数	年龄 (岁)	收缩压 (mmHg)	舒张压 (mmHg)	体力 活动	体重指数	吸烟量 (支/天)	饮酒量 (克/天)	受教育 程度	社会支持
1	252	35.2±6.5	120.7±13.4	78.8±10.2	2.1±0.2	23.1±3.2	8±1	60.1±7.5	4.5±0.8	8.7±1.2
2	253	37.0±6.3	121.2±13.2	77.9±10.5	2.1±0.1	24.0±3.5	10±2	78.2±8.5	4.2±0.9	7.5±1.1
3	252	36.5±6.8	121.1±13.2	78.2±11.0	2.1±0.2	24.8±3.1	15±2	79.3±6.8	3.5±0.8	7.0±1.2
4	253	37.8±6.5	120.4±12.8	78.4±10.6	2.3±0.3	25.8±3.1	15±2	106.8±10.2	3.4±0.8	7.0±1.2
P 值	-	<0.05	0.5	0.39	0.08	<0.01	<0.001	<0.001	<0.05	<0.05

某年某地居民不同心理分值的冠心病危险因素水平比较

2. 统计图形

- 将统计数据形象化
- 可视化让读者更易于领会统计资料的核心内容，易于做分析比较
- 给读者留下深刻的印象


The greatest value of a picture is when it forces us to notice what we never expected to see.
-- John Tukey

图形的最大价值就是使我们注意到从来没有发现的信息

Exploratory Data Analysis


Tukey boxplot (box and whisker plot, Tukey test)

Statistical program: SYSTAT, S language



2.1 统计图形的起源


- 饼图和线图的起源
- 统计图形奠基人之称的苏格兰工程师兼政治经济学家 William Playfair 发明
- The Commercial and Political Atlas




英格兰 1700 年至 1780 年间的进出口数据

2.1 统计图形的起源

- 饼图和线图的起源
- The Statistical Breviary
- 历史上最早出现的饼图



土耳其帝国在三大洲的国土面积分布



各个国家的领土面积（和圆圈成比例）以及人口（左垂线）、税收（右垂线）、国土在各大洲分布比例等数据，两条垂线连线的斜率可表示税负的轻重

2.1 统计图形的起源

- 19世纪伦敦发生霍乱
- 民间
 - 瘴气传播理论
- John Snow
 - 提出怀疑
 - 通过彻底调查这种致命疾病的根源证实了他的怀疑

2.1 统计图形的起源


- 1849 年发表了关于霍乱传播理论的论文
- 这张图是该理论的主要依据
- 图中心的水井是霍乱传播的主要污染源



2.1 统计图形的起源

- 现代护理专业的创始人南丁格尔
- 历史上使用极坐标面积图的先驱
 - 玫瑰图
 - 用花瓣的面积表示统计数值的大小

2.1 统计图形的起源




- 每一瓣代表一个月
- 用颜色标记出了三种死亡原因
 - 蓝色表示死于可预防的疾病
 - 红色表示死于战争伤害
 - 黑色表示死于其它原因

克里米亚战争英国军队自 1854 年 4 月至 1856 年 3 月的逐月死亡人数

2.1 统计图形的起源

- 拿破仑的俄罗斯远征
- 69万人开赴莫斯科，最后2.2万人幸存
- 1812年6月24日到1812年12月14日
- Charles Joseph Minard

2.1 统计图形的起源



大军团进军俄国的路线

撤退时的气温变化

2.1 统计图形的起源


- 大部分是手绘的
- 虽然不精确，但是达到了统计揭示特殊现象或规律上的功能效果
- 现代统计图形：
 - 饼图、条形图泛滥但是没有很好的体现图形价值
 - 人们对统计图形的了解和使用，被统计软件所限

2.2 现代统计图形

- 工具
- 统计作图工具的三原则
 - 统计计算功能齐全
 - 统计元素易于控制
 - 图形类型丰富多样

2.2 现代统计图形

- Microsoft office Excel
- 经常使用的统计图形大部分是Excel的产物




	环比涨跌幅 (%)	同比涨跌幅 (%)	1-9月 同比涨跌幅 (%)
居民消费价格	0.1	-0.3	-0.1
其中：城市	0.0	-0.2	-0.1
农村	0.2	-0.5	-0.3
其中：食品	0.7	-4.4	-1.8
非食品	-0.1	0.7	0.2
其中：消费品	0.3	-0.8	-0.5
服务	-0.3	0.6	0.4
其中：不包括食品和能源	0.0	1.0	0.6
按类别分			
一、食品烟酒	0.5	-2.6	-0.8
粮 食	-0.1	-0.7	-1.2
食 用 油	-0.1	-1.4	-1.8
鲜 菜	6.1	-13.7	-7.9
畜 肉 类	-0.1	-8.4	-2.7
其中：猪 肉	-0.7	-17.0	-2.9
牛 肉	0.9	4.6	-3.4
羊 肉	1.3	0.8	-3.1
水 产 品	-1.8	0.9	1.2
蛋 类	2.7	-11.9	-5.8
奶 类	-0.2	-1.4	-1.4
鲜 果	1.7	-4.2	1.2
卷 烟	0.0	0.0	0.2
酒 类	-0.3	-1.3	-1.9
二、衣着	0.7	1.7	1.5
服 装	0.8	1.8	1.6
鞋 类	0.7	1.4	0.8
三、居住	0.0	0.1	0.1
租赁房租	0.0	0.0	-0.1
水电燃料	0.0	0.4	0.4
四、生活用品及服务	0.3	2.2	0.6
家用器具	0.6	5.5	0.7
家庭服务	0.0	1.6	2.0

各类商品及服务价格同比变动情况（来源：国家统计局）


2.2 现代统计图形

- Microsoft office Excel



2025 年第二季度美国国际投资头寸 (来源: 美国经济分析局)

Figure 24. U.S. Net International Income and Its Components
Percentage of U.S. GDP





Data sources: Bureau of Economic Analysis (national income and product accounts, balance of payments data); Congressional Budget Office.

CBO' s Model and Projections of U.S. International Investment Holdings and Income Flows

2.2 现代统计图形




- Excel 的图形总体有三种
 - 第一种是表现绝对数值大小
 - 条形图
 - 柱形图
 - 折线图



-  柱形图
-  折线图
-  饼图
-  条形图
-  面积图
-  X Y 散点图
-  地图
-  股价图
-  曲面图
-  雷达图
-  树状图
-  旭日图
-  直方图
-  箱形图
-  瀑布图
-  漏斗图
-  组合图


2.2 现代统计图形

- 第二种是表现比例
- 饼图



2.2 现代统计图形

- 第三种是表示二维平面上的变量关系
 - X-Y 散点图



2.2 现代统计图形

- Microsoft office Excel
 - Excel 展示的几乎都是原始数据，基于数据的统计推断的意味比较淡薄
 - 统计学的核心研究对象是分布，例如均值，方差，概率等
 - Excel无法跳出三种类型的限制




Figure 1 | Ascertainment of variants and single-variant results.
a, Sensitivity of low-coverage genome sequence data to detect SNVs in the deep exome sequence data, relative to other variant catalogues. Points represent results for a specific minor allele count. All results assume odds ratio (OR) = 1 for all variants, unless stated otherwise.

b, c, Manhattan plots of single-variant association analyses for: sequence data alone (b, 1,326 cases and 1,331 controls) and meta-analysis of sequence and imputed data (c, total of 14,297 cases and 32,774 controls). 1000G, the 1000 Genomes Project data.


统计图形中的组成元素包括点，线，文本，颜色等，在常见的统计软件中无法灵活操作

2.2 现代统计图形

- 元素
 - 颜色
 - 点
 - 线
 - 网格
 - 标题、文本
 - 坐标轴

2.2 现代统计图形

- 颜色系统
- RGB系统
- 红R, 绿G, 蓝B
- $([0, 255], [0, 255], [0, 255])$



2.2 现代统计图形

- 颜色系统
- 十六进制颜色
- 例如红色： #FF0000
- 相比RGB使用更方便
- 转换： <https://www.rgbtohex.net/>


颜色	英文代码	十六进制	RGB
	LightPink	#FFB6C1	255,182,193
	Pink	#FFC0CB	255,192,203
	Crimson	#DC143C	220,20,60
	LavenderBlush	#FFF0F5	255,240,245
	PaleVioletRed	#DB7093	219,112,147
	DeepPink	#FF1493	255,20,147
	MediumVioletRed	#C71585	199,21,133
	Orchid	#DA70D6	218,112,214
	Thistle	#D8BFD8	216,191,216
	plum	#DDA0DD	221,160,221
	Violet	#EE82EE	238,130,238
	Magenta	#FF00FF	255,0,255
	Fuchsia	#FF00FF	255,0,255

2.2 现代统计图形

- 颜色系统
- 颜色搭配
- 在 Excel 的“页面布局”选项卡或 Word 的“设计”选项卡上，单击“颜色”，然后选择所需的颜色集



- RColorBrewer

```
library(RColorBrewer)
display.brewer.all() #default: type="all"
```




2.2 现代统计图形

- 颜色系统
- <https://nipponcolors.com/>
- <https://zhongguose.com/>



2.2 现代统计图形


- 颜色系统
- 顶刊



Carlo Cervia-Hasler et al. Persistent complement dysregulation with signs of thromboinflammation in active Long Covid. Science, 383, eadg7942 (2024).

2.2 现代统计图形


- 坐标轴系统
- 一般将两轴的相交点即原点处定为0
- 1/2维数据
- X,Y轴（横轴/纵轴）纵横比5：7
- 图中元素所代表数值大小的参照物
- 用不同线条和颜色表达不同对象的统计量，需要附图例加以说明
- 双坐标轴图示



2.2 现代统计图形

```
data(Export.USCN, package = "MSG")
par(mar = c(4, 4.5, .1, 4.5))
# 看似条形图, 实为粗线条, 宽度 lwd = 10
plot(1:13, Export.USCN$Export,
     xlab = "Year / Country",
     ylab = "US Dollars ($10^{16}$)", xaxt = "n",
     lwd = 10, col = c(rep(2, 6), NA, rep(4, 6)),
     panel.first = grid())
# 设置 x 轴的刻度标记: \n 的意思是换行符
xlabel <- paste(Export.USCN$Year, "\n", Export)
xlabel[7] <- ""
abline(v = 7, lty = 2) # 添加一条分隔线
# 使用带有换行符的刻度标记
axis(1, 1:13, labels = xlabel, tick = FALSE, c
# 换算为人民币再计算另一个坐标轴刻度 (汇率 8.27)
ylabel <- pretty(Export.USCN$Export * 8.27)
axis(4, at = ylabel / 8.27, labels = ylabel)
mtext("Chinese RMB ($10^{16}$)", side = 4, line = 2)
box()
```


data(Export.USCN, package = "MSG")
Export.USCN



中美两国 1999~2004 年出口额,
分别以美元和人民币表示


2.2 现代统计图形

- 坐标轴系统



真实性优先于视觉效果，避免通过坐标轴操纵读者判断

2.2 现代统计图形



2.2 现代统计图形

	一维	二维	高维	矩阵
分类数据	条形图	马赛克图	马赛克图	
		关联图、四瓣图		
连续数据	直方图	散点图	平行坐标图	颜色图
	箱线图		散点图矩阵、三维散点图	热图
	Cleveland 点图		三维透视图、平滑散点图	等高图
	一维散点图		星状图、符号图、脸谱图	


各种类型的数据对应的统计图形概览

2.2 现代统计图形

- 条形图 bar chart
 - 用相同宽度的直条长短表示相互独立的某统计指标值的大小
 - 横放/竖放
 - 单式和复式

2.2 现代统计图形

- 复式+横放




Plasma BA concentrations are higher in NASH vs. No-NASH irrespective of T2D status in the ABOS study cohort (n = 219). (A) Plasma total (free + conjugated) BA and C4 concentrations (log-scale, nmol/L) according to NASH status (grey, No-NASH; purple, NASH). (B) Plasma total (free + conjugated) BA and C4 concentrations (log-scale, nmol/L) according to T2D status (left, No-T2D; right, T2D) and NASH status (grey, No-NASH; purple, NASH). Data are expressed as mean and SEM (standard error of mean). p values from the non-parametric Mann-Whitney U test.

Source: NASH-related increases in plasma bile acid levels depend on insulin resistance.

2.2 现代统计图形

- 竖放




(A) Number of OTUs recovered from 16S rRNA gene sequencing of faecal samples from the three health Donor 1 (D1), Donor 2 (D2) and Donor 3 (D3) by MM media and culture-independent methods.

(B) Proportion of OTUs and the corresponding bacterial families from culture MM media as compared to the culture-independent sequencing method.

Source: Mucin-degrading gut commensals isolated from healthy faecal donor suppress intestinal epithelial inflammation and regulate tight junction barrier function

2.2 现代统计图形

- 饼图 Pie chart
- 以圆形总面积作为100%，将其分割成若干个扇面表示事物内部各构成部分所占的比例





表示人类基因组不同结构组件大致百分比的饼图。需注意，除可能构成其他非编码组件的降解元件外，重复元件约占基因组的一半。数据源自 Lander 等人（2001 年）的研究。

2.2 现代统计图形

- 直方图 histogram
- 以直方面积描述各组频数的多少，面积的总和相当于各组频数之和
- 适合表示数值变量的频数分布
- 注意如各组的组距不等时，要折合成等距后再绘图

2.2 现代统计图形

- 直方图




每个荧光颗粒中 GFP 分子数量的估算。

对 80 个光点进行了定量分析：图中展示了 N 值的直方图，其中 $N = (\text{光点每秒总光子通量 } f_{\text{spot}}) \div (\text{细胞每秒总光子通量 } f_{\text{cell}}) \times (\text{GFP 每秒总光子通量 } f_{\text{GFP}})$ 。f 代表每秒总光子通量。

Source: RNA dynamics in live Escherichia coli cells.

2.2 现代统计图形


- 频率直方图
- 另一种表示数值变量资料频数分布的方式
- 将各组段观察频数除以总观察频数得到各组段的频率，以各组段频率除以组距得到的频率密度作为直方图高度，绘制的直方图称为频率直方图



Source: RNA dynamics in live Escherichia coli cells.

2.2 现代统计图形


- 线型图 line graph
- 线图是用线段的升降来表示数值的变化，适合于描述某统计量随另一连续性数值变量变化而变化的趋势，最常用于描述统计量随时间变化而变化的趋势



- A. 诱导后随时间 t 变化的、每个细胞中转录本的估计平均数量
- B. 诱导后随时间 t 变化的、不含标记 RNA 的细胞比例
- Source: Real-Time Kinetics of Gene Activity in Individual Bacteria

2.2 现代统计图形


- 热图 heatmap
- 热图的基础是颜色图
- 颜色图是根据数值的大小对2D数据绘图



简单将一个网格矩阵映射到指定的颜色序列上、以颜色方块表示数据的大小

2.2 现代统计图形

- 热图
- 在颜色图上做了一个特殊处理，就是聚类
- 并非只是简单表达数值大小，而是对矩阵的行或列进行层次聚类，获得聚类的结果之后将行或列以聚类的顺序排列，并在颜色图的边界区域加上聚类的谱系图




热图由微阵列数据的聚类分析生成，展示了颞叶内侧癫痫患者组相对于对照组全血基因组中差异甲基化的 DNA 位点


Source: Blood DNA methylation pattern is altered in mesial temporal lobe epilepsy

2.2 现代统计图形

- 散点图 scatter plot
- 通常用来展示两个变量之间的关系，这种关系可能是线性或非线性的
- 每一个点的横纵坐标都分别对应两个变量各自的观测值，因此散点所反映出来的趋势也就是两个变量之间的关系



2.2 现代统计图形



谢谢

