

医学统计学专论

05. 方差分析 ANOVA



- 方差分析
 - χ^2 和F分布
 - 方差分析的基本方法
 - 方差分析的前提
 - 多重比较

1. χ^2 和F分布

- 卡方分布 (chi-square, χ^2)
- 分类数据的频数分布
 - 如何量化**分类数据的实际观测频数与理论期望频数**的差异?
 - 进而判断差异是抽样误差导致, 还是理论假设 (H_0) 不成立导致?
- 英国统计学家卡尔·皮尔森Karl Pearson
 - 在 1900 年提出
 - 判断观测数据 (分类数据的频数分布) 的偏差是否来自随机抽样

1. χ^2 和F分布

- 卡方分布 (chi-square, χ^2)
- 可以具体化为一些具体的分类变量的频数统计问题
 - 抛硬币 100 次, “正面” 出现 45 次、“反面” 出现 55 次, 这种偏差是否说明硬币不均匀?
 - 某地区人口的职业分布 (农民 / 工人 / 商人) 是否符合1:1:1的理论假设?

1. χ^2 和F分布


- 卡方分布 (chi-square, χ^2)
- χ^2 是由标准正态变量的平方和形成的分布
- 数学定义：
 - 若k个随机变量 $Z_1, \dots, Z_k$ 相互独立且符合标准正态分布 $N(0,1)$ ，则随机变量Z的平方和X可以表示为

$$X = \sum_{i=1}^k Z_i^2$$

- X的分布规律称为卡方分布

1. χ^2 和F分布

- 卡方分布 (chi-square, χ^2)
- X 服从自由度为 k 的卡方分布
 - 当自由度 $v \leq 2$ 时, 曲线呈L形
 - 随着 v 的增加, 曲线逐渐趋于对称
 - 当自由度 V 趋近无穷时, 卡方分布趋近正态分布



卡方分布的概率密度函数

1. χ^2 和F分布

- 皮尔森卡方检验
- 最常见的2×2 列联表卡方检验（分析两个二分类变量）

组别	有效	无效	合计	有效率%
实验组	99(90.48)a	5(13.52)b	104(a+b)	95.20(a/(a+b))
对照组	75(83.52)c	21(12.48)d	96(c+d)	78.13(c/(c+d)))
合计	174(a+c)	26(b+d)	200(n)	87.00((a+c)/n)

判断以上实验组与对照组的有效率是否存在显著差异

原假设H0：处理组与对照组是来自同一总体，有效率一致

备择假设H1：不是同一个总体，有效率不同

1. χ^2 和F分布

- 卡方分布 (chi-square, χ^2)
- 皮尔森卡方公式 (量化实际数据与假设下的理想数据之间的差异程度)

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

- O (实际观测频数) : 必须是某一类别出现的次数
- E (理论期望频数) : 基于分类变量的理论分布假设计算

1. χ^2 和F分布

- 皮尔森卡方检验
- 最常见的 2×2 列联表卡方检验 (分析两个二分类变量)

$$E_{11} = 104 \times 174/200$$

$$E_{12} = 104 \times 26/200$$

$$E_{21} = 96 \times 174/200$$

$$E_{22} = 96 \times 26/200$$

- 所以 $\chi^2 = \sum \frac{(O-E)^2}{E} = 12.857$, $df=(2-1)(2-1)=1$

χ^2 分布表部分 显著水平

自由度	df	0.995	0.99	0.975	0.95	0.90	0.10	0.05	0.025
	1	0.00004	0.00016	0.001	0.004	0.016	2.706	3.841	5.024
	2	0.010	0.020	0.051	0.103	0.211	4.605	5.991	7.378

1. χ^2 和F分布

- 皮尔森卡方检验
- 卡方检验是单侧检验，即右尾检验，因为无论正态分布下的随机变量偏离均值越大，平方和（卡方值）就越大，卡方检验的p值就随之减少
- 可以查询 χ^2 分布表，df=1， $\alpha=0.05$ ， χ^2 大于3.841就拒绝H0，接受H1
- 我们计算得到 $\chi^2=12.857$ ，所以以上结果可以认为差异显著

```
> chisq.test(data, correct = F)
Pearson's Chi-squared test
data:  actual_matrix
X-squared = 12.857, df = 1, p-value =
0.0003362
```

1. χ^2 和F分布


- F分布
- 设X, Y为两个独立的随机变量
 - X服从自由度为d1的卡方分布 $U1 = \sum X_i^2$
 - Y服从自由度为d2的卡方分布 $U2 = \sum Y_i^2$
 - 这两个独立的卡方分布除以各自的自由度后的比率这一统计量的分布, 即服从F分布

$$F = \frac{U1/d1}{U2/d2}$$

1. χ^2 和F分布


- F分布

Histogram for a F-distribution with df1=10, df2=20



1. χ^2 和F分布

- F分布
- F 值的取值区间是 $[0, +\infty)$
- F 分布的平均数 $\mu=1$
- F 分布曲线的性状仅取决于 $df1$ 和 $df2$
 - 当 $df1=1$ 或当 $df1=2$ 时 F 分布曲线呈严重倾斜的方向 J 形
 - 当 $df1 \geq 3$ 时转为左偏曲线
 - 根据 $df1$ 和 $df2$ 查F值分布表



2. 方差分析的基本方法

- 样本平均数的假设检验适用于样本与总体或者两个样本之间的差异显著性检验
- 实际研究中，常需要 3 个及 3 个以上样本平均数进行比较
 - 如果两两相互比较，随着样本平均数个数增加而剧增
 - n 个样本平均数需要比较的次数为 $C_n^2 = \frac{n \times (n-1)}{2}$
- 推断的可靠性降低

2. 方差分析的基本方法

- 有时要按实验设计将所研究的对象分为多个处理组施加不同的干预(比如治疗某种疾病的方式)
 - 处理因素(Treatment, 如用药处理, 手术处理, 药品剂量等)
 - 至少有两个水平(Level, 比如药物剂量有A/B/C三个剂量, 即为3个水平)
- 通过所获得的样本信息来推断各处理组均数间的差别是否有统计学意义, 即处理有无效果

2. 方差分析的基本方法

- 方差分析(Analysis of variance, ANOVA)
- 由英国统计学家R. A. Fisher 首创，为纪念 Fisher.以F命名，故方差分析又称F检验，也称为“变异数分析”
- 方差分析通过分析方差来推断均值是否和总体有显著性差异
 - 虽然叫做方差分析，但是它的目的是检验每个组的平均数是否相同
- F检验有自己的概率分布，依靠F分布为依据，利用离均差平方和与自由度所计算的组间与组内均方估计F值和p值，结合显著水平 α 判断检验结果

2. 方差分析的基本方法

- 方差分析的基本思想
 - 将测量数据的总变异按照变异原因不同分解为处理效应和误差效应，并作出其数量估计
- 样本的方差分为两个来源
 - 处理效应：处理因素(treatment effect, 真实差异)的不同造成
 - 误差效应：天然误差(error effect, 抽样误差或个体差异)造成的，试验过程中的偶尔性因素干扰和测量误差

2. 方差分析的基本方法

- 离均差平方和(Sum of Square of deviations from mean, SS)
- 自由度(Degree of freedom, df)
- 均方(Mean of square, MS)
- 假设：
 - H0: 各个样本来自相同的总体, $\mu_0 = \mu_1 = \mu_2 = \mu_3 = \dots$
 - H1: 各样本是来自不完全相同的总体

2. 方差分析的基本方法

- 方差，即均方(Mean of square, MS)
 - 反映测量数据的变异性指标

$$s^2 = \frac{\sum(x - \bar{x})^2}{df}$$

- 处理因素和误差的比值服从F分布
 - 方差本身就是个体和均值差的平方和
 - 处理效应和误差效应的方差相差不大说明实验处理对指标影响不大
 - 反之相差较大说明实验处理对指标影响很大，不可忽视

2. 方差分析的基本方法

单因素试验为例，假设试验考察的因素有 n 个水平，每个处理重复 m 次，共有 $m \times n$ 个观测值

	1	2	...	j	...	n
1	$X_{1,1}$	$X_{1,2}$	...	$X_{1,j}$	...	$X_{1,n}$
2	$X_{2,1}$	$X_{2,2}$	...	$X_{2,j}$	...	$X_{2,n}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮
i	$X_{i,1}$	$X_{i,2}$	...	$X_{i,j}$	...	$X_{i,n}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮
m	$X_{m,1}$	$X_{m,2}$	...	$X_{m,j}$	...	$X_{m,n}$
处理均值	$\bar{x}_1$	$\bar{x}_2$	...	$\bar{x}_j$	...	$\bar{x}_n$

2. 方差分析的基本方法

- 对于每一个观测值 $x_{i,j}$

$$x_{i,j} = \mu_j + \varepsilon_{i,j}$$

- 对于任意观测值，可以用以上线性可加模型来进行描述
- μ_i 为第 i 个处理观测值总体平均数
- $\varepsilon_{i,j}$ 为试验误差，相互独立，服从标准正态分布 $N(\mu=0, \sigma=1)$

2. 方差分析的基本方法

- 在 H_0 成立的情况下 $\mu_1 = \mu_2 = \mu_3 = \cdots$ ，所有样本混在一起，那么

$$\mu = \frac{1}{n} \sum_{i=1}^n \mu_j$$

- 那么第 j 个处理的处理效应

$$\tau_j = \mu_j - \mu$$

- 这样将观测数据分解成影响观测值大小的各个因素的线性组合

$$x_{i,j} = \mu + \tau_j + \varepsilon_{i,j}$$

2. 方差分析的基本方法

- 这样将观测数据分解成影响观测值大小的各个因素的线性组合

$$x_{i,j} = \mu + \tau_j + \varepsilon_{i,j}$$

 ↑ ↑
 处理效应 随机效应

- μ 所有样本的总体均值
- τ 处理效应所引起的变异
- ε 随机效应所引起的变异

2. 方差分析的基本方法

- 所有样本的总变异可以用总体的方差来度量

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{df}$$

- 依据变异来源将试验资料的总变异分解为相应的变异
 - 处理效应是不同组的均值间差异，叫组间 (between) 变异
 - 组内个体间的差异为同组内的误差，叫组内 (within) 变异
- 总体方差如何分解？

2. 方差分析的基本方法

- 方差是离均差平方和SS除以自由度df
 - 离均差 $x_i - \bar{x}$
 - 离均差平方 $(x_i - \bar{x})^2$
 - 离均差平方和 $\sum (x_i - \bar{x})^2$
 - 自由度 $df = n - 1$
- 方差的分解就是将SS和df分解为变异来源的相应部分

2. 方差分析的基本方法

- a. SS的分解
- 任意观测值 $x_{i,j}$ 与总体平均数 $\bar{x}$ 之差可以表示为

$$x_{i,j} - \bar{x} = (x_{i,j} - \bar{x}_j) + (\bar{x}_j - \bar{x})$$

- 对两边分别平方，以及根据平方和累加后，有

$$\sum_m \sum_n (x_{i,j} - \bar{x})^2 = \sum_m \sum_n (x_{i,j} - \bar{x}_j)^2 + n \sum_m (\bar{x}_j - \bar{x})^2$$

2. 方差分析的基本方法

- 总SS=组间SS+组内SS
- 组内SS

$$\sum_m \sum_n (x_{i,j} - \bar{x}_j)^2$$

- 组间SS

$$n \sum_m (\bar{x}_j - \bar{x})^2$$

2. 方差分析的基本方法

- b. df的分解
- 总的df: $m \times n - 1$
- 组间df: $n - 1$
- 组内df: $(m \times n - 1) - (n - 1) = (m - 1)n$

2. 方差分析的基本方法

- 组间方差：组间SS/组间df

$$\sum_{m} (\bar{x}_j - \bar{x})^2 / n - 1$$

- 组内方差：组内SS/组内df，或者总方差减去组间方差

$$\sum_{m} \sum_n (x_{i,j} - \bar{x}_j)^2 / (m - 1)n$$

2. 方差分析的基本方法

- 组间均方和组内均方的比值，符合F分布
- 均方MS是方差分析中方差的具体形式

$$MS = SS/df$$

- 由此可计算F统计量

$$F = \text{组间}MS / \text{组内}MS$$

2. 方差分析的基本方法

- 因为
 - 组内变异代表随机效应引起的差异
 - 组间变异代表处理效应引起的差异
- 所以
 - 如果F值接近1，说明组间和组内的变异程度接近不能拒绝 H_0
 - 反之F值越大，拒绝 H_0 的理由越充分
- 注意，方差分析是单侧检验

2. 方差分析的基本方法


- 例如,
 - 组间df=9, 组内df=7
 - $\alpha=0.05$
 - 可以查出对应F(0.05, 9, 7)的单尾界值

```
> qf(p=0.05, df1=9, df2=7, lower.tail = FALSE)  
[1] 3.676675
```

- F值大于3.68时, 则p小于0.05, 拒绝H0, 接受H1


2. 方差分析的基本方法

- F检验的图示
 - 比较药物X, Y, Z对治疗某疾病的疗效, 我们将实验对象分成三组, 分别记录服用X, Y, Z三种药物的治疗效果




2. 方差分析的基本方法

- 组间均方 $\approx$ 组内均方, 所以 $F \approx 1$




2. 方差分析的基本方法

- 组间均方 $\gg$ 组内均方，所以 $F > 1$



2. 方差分析的基本方法

- 组间均方 $\ll$ 组内均方, 所以 $F < 1$



3. 方差分析的前提


- F检验是建立在一些假设的基础上，主要有三个
 1. 独立性
 2. 正态性
 3. 方差齐性

3. 方差分析的前提

- 独立性
- 各组内的观测值之间相互独立，且各组数据之间也相互独立（即一个观测值的取值不会影响到其他观测值）
- 独立性是方差分析最核心的假设
- 验证方法：考虑实验设计，随机分组/抽样，回溯数据收集过程，检查数据是否存在相关性

3. 方差分析的前提

- 正态性
- 每一组数据需要服从近似正态分布
- 方差分析基于F统计量，而F统计量的分布前提是数据服从正态分布
- 验证方法：直方图、Q-Q图、Shapiro-Wilk 检验（小样本）、Kolmogorov-Smirnov 检验（大样本）



```
> shapiro.test(iris$Sepal.Length)
      Shapiro-Wilk normality test
data:  iris$Petal.Width
W = 0.90183, p-value = 1.68e-08
> qqnorm(iris$Sepal.Length); qqline(iris$Sepal.Length)
```

3. 方差分析的前提

- 方差齐性
- 各组数据的总体方差相等 (即 $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2$)
- 方差分析中, 组内变异是合并各组方差的估计值, 若各组方差差异较大, 会导致 F 统计量的分布偏离理论分布, 进而影响显著性判断
- 验证方法: 箱线图、Levene 检验、Bartlett 检验 (对正态性较敏感)



```
> bartlett.test(count ~ spray, data = InsectSprays)
      Bartlett test of homogeneity of variances
data:  count by spray
Bartlett's K-squared = 25.96, df = 5, p-value = 9.085e-05
注意: 以上两个检验的H0是存在方差齐性/正态性, 所以p>0.05则假设成立
```


4. 多重比较 (multiple comparison)

- 当方差分析的结果为**拒绝H0，接受H1**时，只说明几组数据之间总体均数不全相等
- 想进一步了解哪两个总体均数不等， 须进行多个样本均数间的两两比较
- 如用样本均数比较的t检验逐个进行——比较，将会加大犯1型错误的概率

4. 多重比较

- 假设检验的两类错误
- 1型错误：把总体均数间本来无差别判为有差别（假阳性）
- 2型错误：把总体均数间本来有差别判为无差别（假阴性）



- 一个假设的接受或否定，不可能保证百分百正确，可能会出现错误的推断
- 通过使用更小的 α 可以降低假阳性的概率

4. 多重比较

- 多次t检验会增加1型错误的概率
 - 用t检验作6次比较
 - 每次比较的检验水准选为 $\alpha=0.05$
 - 则每次比较不犯1型错误的概率为 $(1-0.05)=0.95$
 - 6次均不犯I类错误的概率为 $0.95^6=0.735$
 - 总的检验水准变为 $1-0.735=0.265 > 0.05$

4. 多重比较

- 多重比较的方法
 - LSD法
 - Bonferroni法
 - Dunnett
 - Tukey法
 - SNK 法
 - Duncan法

4. 多重比较

- LSD法

- Least significance difference, 最小显著差异法
- 本质上是一种t检验
- 两样本t检验中, 计算t值使用的是两样本的联合估计方差 s^2

$$t = (\bar{x}_1 - \bar{x}_2) / \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

4. 多重比较

- LSD法
- LSD为达到差异显著的最小差值

$$LSD = t \times \sqrt{s^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

- LSD法采用所有样本的联合方差，而不是要比较的两个样本
- 两组均数差大于LSD时，说明差异达到显著的水平，那就可以拒绝零假设，认为两组均数不相等

4. 多重比较

- LSD法

```
> library(agricolae)
> data(sweetpotato)
> model<-aov(yield~virus, data=sweetpotato)
> LSD.test(model,"virus", p.adj="bonferroni")
$statistics
      MSerror Df      Mean      CV  t.value      MSD
      22.48917  8 27.625 17.1666 3.478879 13.4704
$parameters
      test p.adjusted name.t ntr alpha
Fisher-LSD bonferroni virus   4  0.05
$means
      yield      std r      se      LCL      UCL  Min  Max  Q25  Q50  Q75
cc 24.40000 3.609709 3 2.737953 18.086268 30.71373 21.7 28.5 22.35 23.0 25.75
fc 12.86667 2.159475 3 2.737953  6.552935 19.18040 10.6 14.9 11.85 13.1 14.00
ff 36.33333 7.333030 3 2.737953 30.019601 42.64707 28.0 41.8 33.60 39.2 40.50
oo 36.90000 4.300000 3 2.737953 30.586268 43.21373 32.1 40.4 35.15 38.2 39.30
$groups
      yield groups
oo 36.90000      a
ff 36.33333      a
cc 24.40000     ab
fc 12.86667      b
```

谢谢

