

医学统计学专论

06. 回归分析 Regression




- 回归分析和相关分析
 - 回归分析
 - 相关分析

- 分布主要讨论的是单变量 (univariate) 计量资料的统计分析方法，一般是描述某一变量的统计特征或比较该变量的组间差别
- 在科学实践中，另一类双变量之间关系的研究也值得关注，例如
 - 糖尿病患者血糖和胰岛素水平的关系
 - 某人群年龄的变化与其收缩压的关系
- 这种关系的研究需要线性回归与相关分析的方法

- 和单变量不同，双变量可以表示成成对的形式
- $(x_1, y_1), (x_2, y_2), \dots (x_i, y_i), \dots (x_n, y_n)$
- 每对变量就是在一个个体样本上的观测值，例如一位患者的年龄与其收缩压数值

- 每对观测值在平面直角坐标系中表示成一个点，作成散点图



- 从散点图可以看到变量间关系类型、性质和程度，以及是否有异常值干扰


1. 直线回归

- 当我们用定量关系描述 (x_i, y_i) 在数量上的关系时
 - x_i 自变量
 - y_i 因变量
 - y 是随 x 的变化而变化的，具有随机误差
 - 对于变量 x 的每一个可能值 x_i ，都有随机变量 y_i 的一个分布与之相对应，称随机变量 y 对变量 x 存在回归关系

1. 直线回归

- 与两变量之间严格的直线函数关系不同
- 实际上y随x变化而变化且呈直线趋势，并非y全部都恰好在这条直线上

编号	年龄(X)	尿肌酐(Y)
1	13	3.54
2	11	3.01
3	9	3.09
4	6	2.48
5	8	2.56
6	10	3.36
7	12	3.18
8	7	2.65



1. 直线回归

- 一元回归
 - 一个自变量与一个因变量
 - 直线回归和曲线回归（非线性）
- 多元回归
 - 多个自变量与一个因变量
- 定量关系不等于因果关系

1. 直线回归

- 直线回归方程的建立
- 对于自变量 x 的每一个取值 x_i ，都有因变量 y 的一个分布与之对应
- 根据散点图可以假定：
 - 对于 x 各个取值 x_i ，相应 y 的总体均数 μ_{y_i} 在一条直线上
 - 可以表示为

$$\mu_{y_i} = a + bx_i$$

- a 为截距， b 为回归系数， μ_{y_i} 为因变量 y 对应 x_i 的总体分布上均值的点估计

1. 直线回归

- 直线回归方程的数学模型
- 对因变量 y 总体上的每个实际观测值可以进行分解
 - 因变量 y 的**总体**平均值 μ_y
 - 自变量 x 的变化 $x - \mu_x$ 所引起的 y 的变化 $\beta \times (x - \mu_x)$, β 是总体回归系数
 - 因变量 y 的随机误差 ε

1. 直线回归

- 直线回归方程的数学模型
- 回归方程数学模型可以写成

$$y = \alpha + \beta x + \varepsilon$$

- 其中 α 是总体回归截距，为常量。也是 y 的本底水平，代表自变量对因变量没有影响情况下的 y 值
- 总体回归截距 β ， βx 表示 y 的取值改变，是 x 与 y 的线性回归关系所引起的变化
- 回归估计误差 ε ，也称为残差。是观测值 y_i 与估计值 $\hat{y}_i$ 之间的差值

1. 直线回归

- $y = \alpha + \beta x + \varepsilon$ 模型中的基本假定
 - x 是没有误差的固定变量
 - y 是随机变量，每个观测值 y_i 都存在误差 ε_i
 - 误差 ε 代表因变量 y 的取值改变中未进入该模型或未知但可能与 y 有关的随机和非随机因素共同引起变化的部分
 - 随机误差 ε 是相互独立的，呈正态分布

1. 直线回归

- 建立数学模型 $y = \alpha + \beta x + \varepsilon$ 的第一步是求解方程的两个重要参数 α 和 β
- 最小二乘法 (least squares或者ordinary least squares)
 - 通过最小化**离均差平方和**寻找数据的最佳函数匹配，用于参数估计和曲线拟合
 - 因为计算方法，所以也叫最小平方法
 - 高斯在1809年发明的一种计算天体运行轨迹的方法（天体运动论）


1. 直线回归

- 最小二乘法
- 谷神星的发现
- 提丢斯法则
- $A(n) = 0.3 \times 2^n + 0.4$

行星	实际	预测
水星Mercury	0.387	0.4
金星Venus	0.723	0.7
地球Earth	1	1
火星Mars	1.52	1.6
未知		2.8
木星Jupiter	5.2	5.2
土星Saturn	9.55	10
天王星Uranus	19.2	19.6
海王星Neptune	30.1	38.8

1. 直线回归

- 最小二乘法
- 谷神星的发现
- 皮亚齐在1801年对谷神星进行观测了40天，之后消失，获得不到总轨道1%的数据




1. 直线回归

- 最小二乘法
- 谷神星的发现
- 高斯使用Jan.2, Jan.22, Feb.11三个日期的数据计算出了谷神星轨道得到了其他天文观测者后续的证实
- 高斯认为观测数据存在误差（观测值与实际值之间的差异），误差符合正态分布
- 因为误差符合正态分布，所以算术平均数是减少误差比较好的处理方法

1. 直线回归


- 最小二乘法
- 例如用五把不同颜色的尺子分别测量橡皮的长度，得到的数值分别为：

红	蓝	橙	黄	绿
10.2	10.3	9.8	9.9	9.8




1. 直线回归

- 最小二乘法
- 把测试得到的值画在坐标系中，分别记作 y_i




1. 直线回归

- 最小二乘法
- 可以看成是观测值对橡皮长度长度的拟合，用一个假设的横线表示



1. 直线回归

- 最小二乘法
- 每个点都向 y 做垂线，垂线的长度就是 $y - y_i$ ，也可以理解为测量值和真实值之间的误差：



1. 直线回归

- 最小二乘法
- 用平方 $(y - y_i)^2$ 来代表误差
- 总的误差平方就是 $\sum (y - y_i)^2$
- y_i 是观测值, y 是在计算理想真值的时候需要**拟合**的值
- $\sum (y - y_i)^2$ 随着测量的增加而变大, 但是 y 应该让总平方和在所有可能取值中最小, 也就是

$$\sigma = \min \sum (y - y_i)^2$$

1. 直线回归

- 最小二乘法
- 对这个二次函数求导（极值定理）

$$\frac{d}{dy} \sigma = \frac{d}{dy} \sum (y - y_i)^2$$

$$= 2 \sum (y - y_i) = 2 \times [(y - y_1) + (y - y_2) + \cdots + (y - y_n)] = 0$$

1. 直线回归

- 最小二乘法
- 数据的测量误差是天然存在的
- 多次测量后去算数平均是比较直观的处理方法
- 高斯通过最小二乘法证明了算数平均数是消除误差的最好方法，同时推导出误差是正态分布的

1. 直线回归

- 对于数学模型 $\hat{y} = \alpha + \beta x + \varepsilon$ 中求解方程的两个重要参数 α 和 β
- 令因变量的观测值 y 与回归估计值 $\hat{y}$ 的离均差平方和 $Q = \sum (y - \hat{y})^2$ 值最小

$$\min(Q) = \sum (y - a - bx)^2$$

1. 直线回归

- 根据极值定理，分别对a和b进行求导

$$\frac{\partial Q}{\partial a} = -2 \sum (y - a - bx) = 0$$

$$\frac{\partial Q}{\partial b} = -2 \sum (y - a - bx)x = 0$$

1. 直线回归

- 整理后得到

$$\begin{cases} a \times n + b \sum x = \sum y \\ a \sum x + b \sum x^2 = \sum xy \end{cases}$$

1. 直线回归


- 最终得到

$$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \frac{\sum(x - \bar{x})(y - \bar{y})}{\sum(x - \bar{x})^2} \end{cases}$$

- 计算出 a , b , 将 x 代入 $\hat{y} = a + bx$, 可以计算出 $\hat{y}$

1. 直线回归

- $a > 0$, 截距为正, 在y轴第一象限相交
- $a < 0$, 截距为负, 在x轴第一象限相交
- $b > 0$, 回归系数为正, y 随着 x 增加而增大
- $b < 0$, 回归系数为负, y 随着 x 增加而减小



1. 直线回归

- 研究 y 和 $\hat{y}$ 可以得到如下回归方程的三个基本性质：
 - 平方和最小值 $\min Q = \sum (y - \hat{y})^2$
 - $\sum (y - \hat{y}) = 0$
 - 回归直线通过中心点 $(\bar{x}, \bar{y})$
- 直线回归方程另一种形式

$$\hat{y} = \bar{y} + b(x - \bar{x})$$

1. 直线回归

- 例子
- 黏虫孵化历期平均温度与历期天数之间的关系

平均温度	历期天数
11.8	30.1
14.7	17.3
15.6	16.7
16.8	13.6
17.1	11.9
18.8	10.7
19.5	8.3
20.4	6.7

- 如何建立直线回归方程?

1. 直线回归

- 例子的求解

- $$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \frac{\sum(x-\bar{x})(y-\bar{y})}{\sum(x-\bar{x})^2} \end{cases}$$

- $\bar{x} = \sum x/n, \bar{y} = \sum y/n$



- 得到 $a=57.04, b=-2.53$

- 所以直线回归方程 $\hat{y} = 57.04 - 2.53x$

```
> lm(days~tempreture, data = worms_period )  
Call:  
lm(formula = days ~ tempreture, data =  
worms_period)  
Coefficients:  
(Intercept) tempreture  
57.039 -2.532
```

1. 直线回归

- 结果



- 并非所有的散点都会落在回归直线上，而是靠近回归直线
- 用 x 去估计 y 是存在随机误差的
- 必须根据回归的数学模型对随机误差进行估计，对回归方程进行检验

1. 直线回归

- 直线回归结果的假设检验
- 因变量 y 是随机变量
- y 的变异可以表示为 $y - \bar{y}$
 - y 的变异可能是自变量 x 造成的，也可能是随机误差造成的
 - 由 x 引起的变异表示为 $(\hat{y} - \bar{y})$
 - 误差所引起的变异表示为 $(y - \hat{y})$

1. 直线回归

- 直线回归结果的假设检验
- y 的总变异可以表示为

$$\Sigma(y - \bar{y})^2 = \Sigma(\hat{y} - \bar{y})^2 + \Sigma(y - \hat{y})^2$$

- $\Sigma(\hat{y} - \bar{y})^2$ 为由 x 变异引起 y 变异的平方和，也就是在 y 的变异中可以用 x 解释的部分。该值越大说明回归效果越好
- $\Sigma(y - \hat{y})^2$ 为误差因素引起的平方和，反映了除去 x 以外的其余因素使 y 发生变异的部分，也就是无法用 x 解释的部分。该值越小说明估计误差越小

1. 直线回归

- 直线回归结果的假设检验
- 通过F检验比较回归平方和与残差平方和，以确定他们之间是否存在线性关系
- 所以对检验进行的假设应该是
 - H_0 : 两变量之间无线性关系
 - H_1 : 两变量之间存在线性关系

1. 直线回归

- 直线回归结果的假设检验
- 在 H_0 下，回归 (hg) 平方和与残差平方和 (cc) 的比值服从 F 分布
- 总体 $df=n-1$ ，回归自由度 $df=1$ ，残差 $df=n-2$

$$F = \frac{MS_{hg}}{MS_{cc}} = \frac{\frac{SS_{hg}}{df_{hg}}}{\frac{SS_{cc}}{df_{cc}}}$$

1. 直线回归

- 直线回归结果的假设检验
- 统计分析软件一般会直接计算出回归分析的显著性结果

```
> summary(lm(days~tempreture, data = worms_period ))
Call:
lm(formula = days ~ tempreture, data = worms_period)
Residuals:
    Min       1Q   Median       3Q      Max
-2.5239 -1.1426 -0.1087  1.2685  2.9343
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   57.0393      4.5509   12.53 1.58e-05 ***
tempreture    -2.5317      0.2671   -9.48 7.85e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1



Residual standard error: 1.984 on 6 degrees of freedom
Multiple R-squared:  0.9374,    Adjusted R-squared:  0.927
F-statistic: 89.87 on 1 and 6 DF,  p-value: 7.848e-05
```

1. 直线回归

- 直线回归结果的评价
- 构建回归模型时，我们不仅要让模型跑起来，更关键的是要准确评估其表现
- 好的评估指标能告诉我们模型预测的准确度、鲁棒性以及是否抓住了数据的核心规律
- 每个评估指标都有各自的优劣势

1. 直线回归

- 直线回归结果的评价指标
- 残差图
- 残差应随机分布（无明显聚类或趋势），否则可能存在未捕捉的变量或非线性关系
- 残差的离散程度应大致均匀（无“漏斗形”或“喇叭形”），否则可能违反方差齐性假设



1. 直线回归

- 直线回归结果的评价
- 平均绝对误差MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- 衡量预测值与实际值之间平均偏差程度
- MAE 的单位与实际值 / 预测值一致，直观易懂
- 对异常值的敏感性低于均方误差（MSE），更稳健

1. 直线回归

- 直线回归结果的评价
- 均方误差MSE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 将MAE的绝对值变成了平方
- 对大误差给予更高的权重，对离群点敏感，便于求导优化
- 单位量纲是实际值/预测值的平方

1. 直线回归

- 直线回归结果的评价
- 平均绝对误差RMSE

$$\text{RMSE} = \sqrt{\text{MSE}}$$

- 兼顾 MSE 的敏感性与 MAE 的可解释性，是应用最广的指标之一
- 与目标同量纲

1. 直线回归

- 直线回归结果的评价
- 均一化均方根误差NRMSE, Normalized RMSE

$$NRMSE = RMSE / z, z = \max(y_i) - \min(y_i) \text{ 或 } \bar{y} \text{ 或 } \sigma_y$$

- RMSE经过归一化处理, 核心作用是消除数据量纲影响, 便于不同数据集、不同模型之间的误差对比
- NRMSE 越小, 模型预测精度越高
- 跨场景模型评估的常用指标

1. 直线回归

- 直线回归结果的评价
- 决定系数 (R方, R^2)

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

残差平方和

总平方和

- 数学意义为模型解释数据方差的百分比
- 越接近 1 越好, 但可能为负
- 没有量纲

1. 直线回归

- 直线回归结果的评价
- 调整后决定系数, adjusted R^2
- 并非变量越多, 模型越好
- 只要往模型中添加自变量, R^2 就会增大或保持不变, 哪怕新增加的变量无关
- 引入样本量 n 和自变量个数 k 构建惩罚项, 修正 R^2 的高估问题

$$\text{adj}R^2 = 1 - \frac{\sum(y_i - \hat{y})^2 / n - k - 1}{\sum(y_i - \bar{y})^2 / n - 1}$$

残差的自由度

总平方和自由度


2. 相关分析 covariance & correlation

- 变量 x 和变量 y 无自变量和因变量之分，都具有随机误差
- 随机变量 x 和 y ，对于其中任一随机变量的每一个可能的值，另一个随机变量都有一个确定的分布与之相对应，称这两个变量间存在相关关系
- 相关分析用来衡量两个或者多个变量之间的关联强度和方向
 - 直线相关分析：两个变量的线性关系
 - 偏相关分析：其余变量保持不变的情况下两个变量间的线性相关
 - 复相关分析：一个变量与多个变量间的线性相关

2. 相关分析

- 协方差covariance
- 方差是用来刻画数据波动性的统计量
- 协方差就是描述两个变量之间的变动关系
- 通俗地理解为，两个变量是同向变化还是向变化？同向或反向程度有多少？

变量X和Y的波动趋势与均值



2. 相关分析

- 协方差covariance
- 例如对于两组数据X和Y，X变大，Y也变大，说明是同向变化，协方差为正值
- 协方差的绝对值越大，则两个变量同向或反向的程度也越大，即有较强的相关
- 可以考虑用离均差的乘积来计算双变量 x 与 y 的关系

$$\sum (x_i - \mu_x)(y_i - \mu_y)$$

- μ_x, μ_y 分别代表两组变量的均值

2. 相关分析


- 协方差covariance
- 协方差的核心逻辑是离均差乘积的平均

$$\text{Cov}(x, y) = \frac{1}{N} \sum (x_i - \mu_X)(y_i - \mu_Y)$$

- 对每个数据点，计算x离均差($x_i - \mu_X$)，以及y离均差($y_i - \mu_Y$)
- 将两个偏差相乘，得到离均差乘积项
- 对所有乘积和取平均（对总体来说是N，对样本的无偏估计就是n-1）

2. 相关分析

- 协方差covariance
- 同向运动，离均差正负号相同，最后计算都是正值
- 反之，反向运动则计算出来都是负值
- 如果是杂乱运动的，则正负抵消




2. 相关分析

- 可以用散点图来表示离均差的分布
- 对于每一对 x_i, y_i , 都可以映射到笛卡尔坐标系中
 - 原坐标转变为 $(x_i - \mu_x), (y_i - \mu_y)$
 - 均值 μ_x, μ_y 为原点


2. 相关分析

- 如果数据点多落在 I 和 III 象限, 由于
 - 在第 I 象限 $(x_i - \mu_x) > 0, (y_i - \mu_y) > 0$
 - 在第 III 象限 $(x_i - \mu_x) < 0, (y_i - \mu_y) < 0$
 - 离均差乘积和 $\sum(x_i - \mu_x)(y_i - \mu_y) > 0$
 - 在 I 和 III 象限的数据点越多, 离均差的乘积和越大




2. 相关分析

- 如果数据点多落在II和IV象限，由于
 - 在第II象限 $(x_i - \mu_x) < 0, (y_i - \mu_y) > 0$
 - 在第IV象限 $(x_i - \mu_x) > 0, (y_i - \mu_y) < 0$
 - 离均差乘积和 $\sum (x_i - \mu_x)(y_i - \mu_y) < 0$
 - 在 II 和 IV 象限的数据点越多，离均差乘积和的绝对值越大



2. 相关分析

- 散点均匀分布在四个象限中，正负相消
- 离均差乘积和 $\sum(x_i - \mu_x)(y_i - \mu_y) \approx 0$



2. 相关分析

- 离均差的乘积和可用以表示直线相关的两个变量的相关程度和性质
- 但是不同数据之间的乘积和无可比性, x 和 y 的变异程度及其度量单位会影响乘积和的结果
- 为了消除影响, 转换离均差为各自的标准差, 再除以 N

$$\rho = \frac{1}{N} \sum \frac{(x_i - \mu_x)}{\sigma_x} \times \frac{(y_i - \mu_y)}{\sigma_y}$$

2. 相关分析

- 相关系数 $r \in [-1, 1]$
- 如果绝对值为1, 绝对相关
- 绝对值越接近1, 相关程度越高; 越接近0, 相关程度越低
- r 的正负表示相关的性质, 正相关即 x 增大时 y 也增大, 负相关即 x 增大时 y 减少

2. 相关分析 correlation

- 相关系数的假设检验
- 检验 r 是否来自 $\rho \neq 0$ 的总体
- 因为即使从 $\rho = 0$ 的总体作随机抽样，由于抽样误差的影响，所得 r 值也常不等于零
- 一般用 t 检验， S_r 为相关系数的标准误

$$t = \frac{r}{S_r} = \frac{r}{\sqrt{1 - r^2 / n - 2}}$$

3. 直线回归与相关分析的注意事项

- 根据分析目的选择自/应变量和统计方法
- 进行直线回归和相关分析前绘制散点图，对离群值提前处理
- 用残差图考察数据是否符合模型假设条件
 - 自变量与因变量关系为线性
 - 误差服从均数为0的正态分布且方差相等
 - 各观测独立

3. 直线回归与相关分析的注意事项

- 结果的解释与正确应用
 - 观测值要尽量多
 - 回归方程和相关系数应进行检验
 - 预测和外推要谨慎
 - 理解相关系数的含义：相关不等于因果

谢谢

