

医学统计学专论

07. 非线性回归


Nonlinear regression



- 非线性回归
 - 可直线化
 - 多项式

- 线性关系
- 直线关系是两个变量间最简单的关系
- 在较小取值范围内，任意非线性关系都可以用线性关系来表示。
- 缩小研究范围在使用上很不方便：
 - 不能对变量间关系有一个整体上的把握
 - 在不同取值范围内还要换用不同的方程


- 酶联免疫吸附试验ELISA标准曲线
- 抗体浓度-吸光度标准曲线
- 当抗体浓度较低时，体系中抗原过量，抗体与抗原的结合率随抗体浓度升高而线性上升
- 当抗体浓度达到一定阈值后，抗原逐渐被耗尽，抗体结合率不再随浓度升高而显著增加，吸光度增长变缓，最终趋于平稳
- 注意：抗体浓度临床参考区间





- 非线性关系
- 在研究过程中经常可以遇到变量间的非线性关系，用来表示两个变量间关系的曲线种类很多
- 如果数据中的潜在模式呈现出曲线形态，无论是指数增长、衰减、对数形式还是其他任何非线性形式，拟合非线性回归模型都能更准确地反映这种关系
- 非线性回归是一类范围更广的回归模型，在这类模型中，因变量 y 和自变量 x 之间的关系并不被假定为线性的

- 米氏动力学模型Michaelis-Menten kinetics
- 描述多种非变异构酶动力学现象

- $V_0 = V_{max} \frac{[S]}{K_M + [S]}$



- 种群动态population dynamics
- 种群的规模和组成随时间的变化情况
- 生态学运用多种数学方法来模拟种群动态
- 一些模型描述的是不受环境限制的增长
- 另一些模型则包含了由有限资源所决定的 “上限”



- 非线性回归分析
- 已知曲线（公式）类型
 - 如果已知曲线类型，回归效果会有保证
 - 在多数情况下我们对所研究的对象都有一定的了解，可以根据理论和经验得出可能的曲线类型
- 未知曲线（公式）类型
 - 如果曲线类型未知，可以利用多项式回归
 - 通过逐渐增加多项式的高次项来拟合，从而确定最优回归方程

1. 可直线化

- 生物医学中变量间的曲线关系：
 - 倒数函数曲线
 - 指数函数曲线
 - 对数函数曲线
 - 幂函数曲线
 - S 形曲线
- 判断曲线关系需要借助于有关专业知识所提供的推断，不应和专业实践结果相矛盾

1. 可直线化

- 曲线类型
- 确定曲线类型是非线性回归分析的关键
- 通常的方法：
 - 图示法：根据所获得的试验资料的自然尺度绘出散点图，按照散点图的趋势绘出能够反映它们之间变化规律的曲线，与已知的曲线相比较，找出与之较为相似的曲线图形
 - 直线化法：将原始数据进行转换，将曲线方程直线化，用转换后的数据绘出散点图，若图形为直线趋势，表明所选取的曲线类型是恰当的

1. 可直线化

- 评价曲线的方法
- 曲线和观测值配合的好坏，通常以所配曲线与实测点吻合程度的高低来衡量
- 吻合程度取决于离回归平方和与总平方和的比例大小，如果比例小，说明所配曲线与实测点吻合程度高，反之则低
- 决定系数

1. 可直线化

- 总体流程：
 - 1. 对于同一组实测数据，根据散点图性状，用若干相近的曲线进行拟合，同时建立若干曲线回归方程
 - 2. 根据决定系数的大小和生物学专业知知识，选择既符合生物学规律，又有较高拟合度的曲线回归方程来描述两个变量间的曲线回归关系

1. 可直线化

- 对非线性化回归曲线的直线化方法
- 直接引入新的变量

统计学已经证明，大部分曲线方程只要变量变换后的直线化回归关系达到显著，变量反转后得到的曲线回归关系也较好

- 例如对数函数方程

- $y = a + b \times \log x$, 令 $x' = \log x$, 得到 $y = a + bx'$

- 将原曲线方程进行数学变换后引入新的变量

- 例如幂函数曲线方程

- $y = a \times x^b$, 取对数得 $\lg y = \log a + b \times \log x$, 得到 $y' = a' + bx'$

1. 可直线化

- 倒数函数曲线
- 常见表达式




$$\hat{y} = \frac{a + bx}{x}$$

$$\hat{y} = \frac{1}{a + bx}$$

$$\hat{y} = \frac{x}{a + bx}$$

1. 可直线化

- 倒数函数曲线
- 对应的图形



1. 可直线化

- 倒数函数曲线
- 对倒数函数进行直线化的方式
- 通过变量替换将非线性的倒数函数关系转化为线性函数关系
- 例如 $\hat{y} = \frac{1}{a+bx}$, 令 $y' = \frac{1}{y}$, 则 $\hat{y}' = a + bx$
- 或者 $\hat{y} = \frac{a+bx}{x}$, 令 $x' = \frac{1}{x}$, 则 $\hat{y}' = ax' + b$

1. 可直线化

- 倒数函数曲线
- 第1步：观察原函数的非线性项，确定变量替换方案
- 对于通用形式 $\hat{y} = \frac{a}{x} + b$ ，其非线性源于 $1/x$ 与 y 的关系
- 若令新自变量 $x' = 1/x$ ，则原函数可直接转化为： $y = ax' + b$
- 此时，函数已转化为标准的一元线性函数

1. 可直线化

- 倒数函数曲线
- 第2步：验证变量替换的合理性
- 根据实际观测数据，先通过“变量替换”生成新的样本对 (x', y) ，再验证其线性相关性
- 对每个原始数据 x' ，计算 $x' = 1/x$ （需排除 $x=0$ 的无效数据）
- 观察散点是否大致呈直线分布，若散点趋势接近直线，说明变量替换有效

1. 可直线化

- 倒数函数曲线
- 第3步：基于线性化结果进行分析
- 若线性化有效，可对 $y = ax' + b$ 进行后续操作
- 参数拟合：用线性回归方法计算新线性方程的斜率a和截距b，得到原倒数函数的具体表达式
- 预测与误差分析：通过线性函数的预测区间，反推原变量 x 对应的y的取值范围，且线性回归的误差分析（如残差检验）可直接复用，简化计算

1. 可直线化


- 倒数函数曲线
- 倒数函数的直线，本质是通过 $x' = 1/x$ 或者 $y' = 1/y$ 的变量替换，剥离非线性项，转化为可直接分析的线性关系
- 注意这些函数的使用条件
 - 倒数函数中， x 的观测值没有0值
 - 数据异常值影响，例如非常小的 x 会敏感，从极小值变成极大值
 - 不可混淆于其他非线性函数

1. 可直线化

- 倒数函数曲线 demo
- ‘苏品 1 号’ 玉米在不同密度下的平均株重和经济系数的关系

```
maize <- data.frame(  
  x = c(399, 329, 247, 191, 145, 119, 90),  
  y = c(0.38, 0.379, 0.371, 0.343, 0.317,  
        0.301, 0.248))
```

- 绘制散点图，发现与 $\hat{y} = \frac{a+bx}{x}$ 中 $a < 0, b > 0$ 的曲线相似



1. 可直线化

- 倒数函数曲线 demo
- 计算 x 和 $y' = x \times y$ 的相关系数并对其进行显著性检验

```
> cor.test(maize$x, maize$x*maize$y, alternative = "two.sided", conf.level = 0.99)
## Pearson's product-moment correlation

## data: maize$x and maize$x * maize$y
## t = 82.675, df = 5, p-value = 4.906e-09
## alternative hypothesis: true correlation is not equal to 0
## 99 percent confidence interval:
## 0.9952064 0.9999722
## sample estimates:
## cor
## 0.9996344
```

1. 可直线化


- 倒数函数曲线 demo
- 配合倒数函数方程，进行直线回归分析，得到 a 和 b 值

```
> lm(x * y~x, data = maize)
##
## Call:
## lm(formula = x * y ~ x, data = maize)
##
## Coefficients:
## (Intercept) x
## -14.5363 0.4206
```

- 代入公式，得到 y 和 x 之间的倒数函数方程 $y = \frac{-14+0.42x}{x}$

1. 可直线化

- 倒数函数曲线 demo
- 配合倒数函数方程，进行直线回归分析，得到 a 和 b 值



1. 可直线化



- 指数函数曲线
- 常见表达式
- 核心特征为指数是自变量 x ，自变量 x 必须在指数上，而非底数或系数中；
底数 a 是大于 0 且不等于 1 的常数

$$y = ae^{bx}$$

$$y = ab^x$$


1. 可直线化

- 指数函数曲线



1. 可直线化

- 指数函数曲线
- x 是作为指数出现的, 一般系数 b 用以描述增长或衰减速率
- 例如对于 $y = ae^{bx}$ 来说
 - $b > 0$ 表示增长曲线
 - $b < 0$ 表示衰减曲线





1. 可直线化

- 指数函数曲线
- 对指数函数进行直线化的方式
- 利用对数变换消除 “指数含自变量” 的非线性特征，将形如 $y = a \times b^x$ （或衍生形式）的非线性关系，转化为 $y = a + bx$ 的线性关系
- 例如 $y = ae^{bx}$ ，可以两边取自然对数得到 $\ln y = \ln a + bx$
- 令 $y' = \ln y$ ， $a' = \ln a$ ，则方程变为 $y' = a' + bx$
- 即可求出 a' 和 b （ $a' = \ln a$ ），代入原方程即可

1. 可直线化

- 对数函数曲线，常见表达式 $\hat{y} = a + b \lg x$ ，转换 $x' = \lg x$
- 幂函数曲线，常见表示式 $\hat{y} = ax^b$ ，两边取对数变成 $\log y = \log a + b \log x$




1. 可直线化

- 判断曲线的函数类型
- 1. 自变量的运算位置与形式
 - 自变量在指数、底数、分母、对数上，运算形式不同，曲线形态完全不同
- 2. 增长 / 衰减的速率特征
 - 指数函数是指数级增速 / 衰减，后期会爆发式增长或快速趋近于 0
 - 线性函数是匀速变化
 - 对数函数是增速逐渐放缓，最终趋近于平缓

1. 可直线化

- 判断曲线的函数类型
- 3. 定义域、值域与特殊约束
 - 特别是自变量 x 的取值范围
- 4. 特殊点与渐近线
 - 函数的渐近线、固定经过的特殊点，是函数的身份标识，比如指数函数过 $(0,1)$ 且有水平渐近线，对数函数过 $(1,0)$ 且有垂直渐近线

1. 可直线化



2. 多项式回归

- 多项式回归是线性回归的扩展
- 在线性的基础上进行叠加多次项
- 对应一些现实研究问题，例如运动员提高成绩，每个分段的提升，训练难度也会逐级加大，所需要的时间也会更多
- 多项式是指由若干个单项式相加组成的代数式，单项式中最高项次就是这个多项式的次数
- 二次函数 $y=ax^2+bx+c$ ，三次函数 $y=ax^3+bx^2+cx+d$
- 按自变量个数可分为一元和多元多项式回归

2. 多项式回归

- 多项式回归的通用形式

$$y = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \cdots + \beta_k z_k + \varepsilon$$


- $z_1, z_2, \dots, z_k$ 是自变量的基函数，例如 $x, x^2, x_1 x_2$
- ε 是随机误差项 多项式次数越高，曲线越复杂（过拟合风险）（满足正态分布、方差齐性等假设）
- 回归系数 β 不受到非线性运算的影响（虽然自变量是高次项，但回归系数仍为线性，即系数与因变量呈线性关系）

2. 多项式回归


- 多项式次数越高，曲线越复杂（过拟合风险）
- 次数
 - 次数决定曲线灵活度：次数越大，曲线越能贴合数据，但易出现 过拟合（训练集效果好，测试集效果差）
- 系数
 - 一次项系数 β_1 反映线性趋势强度，二次项系数 β_2 反映曲线弯曲方向

2. 多项式回归

一次项系数 β_1 的影响：线性趋势强度与方向
固定 $\beta_0=1$, $\beta_2=0.5$, 仅改变 β_1




二次项系数 β_2 的影响：曲线弯曲方向
固定 $\beta_0=1$, $\beta_1=1$, 仅改变 β_2




2. 多项式回归

- 多项式的次数越高，拐点数量的上限越高



2. 多项式回归

- 多项式的次数越高，拐点数量的上限越高



2. 多项式回归

- 回归系数的求解
- 先将高次项 x^2, x^3 视为 新的自变量, 令

$$z_1 = x,$$

$$z_2 = x^2,$$

$$\dots,$$



$$z_n = x^n$$

- 转化为 $y = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \dots + \beta_k z_k$
- 再用最小二乘法求解

2. 多项式回归

- 多项式回归中的多重共线性问题
- 核心原因：高次项由同一个原始自变量衍生而来
- 一元多项式回归的 x 、 x^2 、 x^3 等项，本质都源于原始变量 x ，变量间会天然呈现极强的线性关联，这种关联就是多重共线性
- 例如
 - 原始变量 x 的取值是 $[1, 2, \dots, 20]$ ，那么 x^2 能够继承并放大 x 的增长趋势

2. 多项式回归



2. 多项式回归

- 如何解决多重共线性问题
- 中心化/标准化数据
- 中心化

$$x' = x - \bar{x}$$



- 标准化

$$x' = \frac{x - \bar{x}}{S_x}$$

2. 多项式回归

- 如何解决多重共线性问题
- 中心化/标准化数据能够消除原始变量及其高次项之间的 “线性趋势叠加”，降低变量间的线性相关性
 - 中心化: $x' = x - \bar{x}$
 - 那么 $x'^2 = (x - \bar{x})^2 = x^2 + 2\bar{x}x + \bar{x}^2$
- 这样中心化让高次项摆脱了对原始变量线性趋势的依赖，转而突出自身的非线性特征，从而降低与原始变量的线性相关性

2. 多项式回归



2. 多项式回归

- 多项式回归的统计检验
 - 1. 整体模型检验（判断多项式是否比无自变量模型更有效）
 - H_0 : 所有高次项系数均为 0（模型无效）
 - H_1 : 至少有一个系数不为 0（模型有效）
- 通过比较模型解释的方差与残差方差的比值（F值），判断模型是否显著

2. 多项式回归

- 多项式回归的统计检验
 - 1. 回归系数检验（判断高次项是否不为0，是否有必要在模型中）
 - H_0 : 某高次项系数为 0（对因变量变化无作用）
 - H_1 : 某高次项系数不为 0（对因变量变化有作用）
- 通过t检验计算t 值（系数 / 标准误）判断系数是否显著异于 0
- 多项式回归中，高次项与低次项存在递进关系，保留高次项必须保留前项

2. 多项式回归

- 多项式回归在生物医学中的意义
- 精准捕捉生物系统中普遍存在的非线性关系
- 无需预设理论模型（如 Logistics、指数模型），即可通过多项式项捕捉拐点、增速变化、饱和效应
- 肿瘤生长预测、生理指标波动、药物代谢动力学

2. 多项式回归

- 优势
- 无强先验假设：无需提前知道生物过程的理论模型，仅通过数据本身挖掘趋势
- 易解释性：相比神经网络等黑箱模型，多项式的系数可解读，符合生物医学研究需机制解释的需求
- 兼容性强：可与其他统计方法结合，如正则化 Ridge/Lasso 避免过拟合、与生存分析结合优化预后模型

谢谢

