

医学统计学专论

04. 多元统计 Multivariate Statistics



- 多元统计主要涉及到
 - 简化数据结构问题（降维问题）
 - 分类与判别（归类问题）
 - 变量间相互联系（回归问题和典型相关分析）
 - 多元数据的统计推断

- 多元统计分析是以 p 个变量的 n 次观测数据所组成的数据矩阵为依据，一般描述为 n 行 p 列矩阵或者 $X = (x_{ij})_{n \times p}$

$$X = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{pmatrix}$$

1. 矩阵及矩阵运算

- 矩阵的定义
- 由 $n \times p$ 个实数排列组成的 n 行, p 列方形列表

$$A = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix}$$

- 记做 $A = (x_{ij})_{n \times p}$, 其中 $x_{i,j}$ 是第 i 行, 第 j 列的元素

1.矩阵及矩阵运算

- 特殊矩阵
- 零矩阵 O : $x_{i,j} = 0$, 全1矩阵 J : $x_{i,j} = 1$
- 方阵: $n = p$, p 阶矩阵
 - 方阵存在对角线
 - 上三角 (下方为0) 和下三角矩阵 (上方为0)
 - 对角矩阵: 非对角线元素为0, $A = \text{diag}(x_{11}, x_{22}, x_{33}, \dots, x_{pp})$
 - 单位矩阵 I_p : 对角矩阵中对角线元素为1

1.矩阵及矩阵运算

- 矩阵的转置
- 矩阵A的行列互换，称为转置，记作 A' 或者 A^T

$$A = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix}, \quad A' = \begin{bmatrix} x_{1,1} & x_{2,1} & \cdots & x_{n,1} \\ x_{1,2} & x_{2,2} & \cdots & x_{n,2} \\ \vdots & \vdots & \vdots & \vdots \\ x_{1,n} & x_{2,n} & \cdots & x_{n,p} \end{bmatrix}$$

- 在方阵中，如果 $A = A'$ ，因为行列对称，那么称为对称矩阵

1.矩阵及矩阵运算

- 矩阵加法

- 如果两个同型矩阵 $A = (a_{ij})_{n \times p}$, $B = (b_{ij})_{n \times p}$ 相加, 那么

$$A + B = (a_{ij} + b_{ij})_{n \times p}$$

- 在一些领域出现矩阵加实数 c 的表述, 本质是矩阵与元素全为该实数的同型矩阵 $(c \times J)$ 相加

1.矩阵及矩阵运算

- 矩阵乘法
- 矩阵 $A = (a_{ij})_{n \times p}$ 与实数 c 相乘, 定义为

$$A \cdot c = (a_{ij} \times c)_{n \times p}$$

- 矩阵 $A = (a_{ij})_{n \times q}$, $B = (b_{ij})_{q \times p}$ 相乘, 定义为 $A \cdot B = (\sum_{k=1}^q a_{ik} \times b_{kj})_{n \times p}$
 - 行数与左矩阵 A 相同, 列数与右矩阵 B 相同
 - 矩阵第 i 行第 j 列的元素由 A 的第 i 行元素与 B 的第 j 列元素对应相乘, 再取乘积之和

$$\begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \times \begin{bmatrix} 1 & 2 & -3 \\ -1 & 1 & 2 \end{bmatrix} = \begin{bmatrix} -1 & 4 & 1 \\ 2 & 1 & -5 \end{bmatrix}$$

1. 矩阵及矩阵运算

- 逆矩阵
- 矩阵里没有除法，只有逆矩阵。
- 如果 $A \cdot B = B \cdot A = I$ ，称B是A的逆矩阵
- 一定是方阵才有逆矩阵
- 假如有矩阵A，B，求矩阵X： $X \cdot A = B$ ，需要两边乘以 A^{-1}

$$XA \cdot A^{-1} = B \cdot A^{-1}$$

$$XI = X = B \cdot A^{-1}$$

1.矩阵及矩阵运算

- 逆矩阵的求解

```
>matrix_A <- matrix(c(1.65640, -1.49800, -3.63000,  
-1.49800, 36.89875, 83.80000,  
-3.63000, 83.80000, 320.00000),  
nrow = 3, ncol = 3)  
>inverse_matrix <- solve(matrix_A)  
>inverse_matrix
```

1.6564	-1.4980	-3.6300
-1.4980	36.8988	83.8000
-3.6300	83.8000	320.0000

```
## [,1] [,2] [,3]  
## [1,] 0.626886834 0.02294788 0.001101772  
## [2,] 0.022947876 0.06771345 -0.017472144  
## [3,] 0.001101772 -0.01747214 0.007713016
```

1. 矩阵及矩阵运算

- 协方差矩阵
- 给定一个矩阵X，协方差矩阵是一个方阵，代表任意两列随机变量之间的协方差
- 假如有一个数据集{x, y, z}，有三个维度，那么协方差矩阵就是如下

$$\begin{bmatrix} \text{Cov} & x & y & z \\ x & \text{Cov}(x, x) & \text{Cov}(x, y) & \text{Cov}(x, z) \\ y & \text{Cov}(y, x) & \text{Cov}(y, y) & \text{Cov}(y, z) \\ z & \text{Cov}(z, x) & \text{Cov}(z, y) & \text{Cov}(z, z) \end{bmatrix}$$


方差：对角线上的元素
协方差：非对角线元素

1.矩阵及矩阵运算

- 相关系数矩阵
- 相关矩阵是通过协方差矩阵标准化得出的，其元素是变量之间的皮尔逊相关系数，取值范围在-1到1之间
- 消除了变量量纲的影响，更直接地衡量了变量之间的线性相关强度

2. 多元回归

- 多元分布
- 多元正态分布是理论性质比较优良的分布
- 线性变换仍保持多元正态分布不变
- 边缘分布和条件分布仍为正态分布,
- 分布完全由一二阶矩决定



2. 多元回归

- 多元线性回归分析
- 具一个因变量 y 与两个或两个以上自变量 x ，且各自变量均为一次项的回归
- 以多元线性回归模型为基础，根据最小二乘法建立正规方程，求解得出多元线性回归方程，并对回归方程和偏回归系数进行检验，作出回归方程的区间估计

$$y_i = \mu_y + \beta_{y1}(x_1 - \mu_{x_1}) + \beta_{y2}(x_2 - \mu_{x_2}) + \cdots + \beta_{ym}(x_m - \mu_{x_m}) + \epsilon_i$$

2. 多元回归

- 多元线性回归方程

$$\hat{y} = a + b_1x_1 + b_2x_2 + \cdots + b_mx_m$$

- 多元线性回归方程可以根据最小二乘法求解，也就是求以下方程的最小值

$$\begin{aligned} \min(Q) &= \sum (y - \hat{y})^2 \\ &= \sum [y - \bar{y} - b_1(x_1 - \bar{x}_1) - b_2(x_2 - \bar{x}_2) - \cdots - b_m(x_m - \bar{x}_m)]^2 \end{aligned}$$

$$\sum (Y - b_1X_1 - b_2X_2 - \cdots - b_mX_m)^2$$

2. 多元回归

- 多元线性回归方程系数求解
- 根据极值定理, 使 $b_1, b_2, \dots, b_m$ 的偏微分方程皆等于 0, 就有

$$\begin{cases} \frac{\partial Q}{\partial b_1} = -2 \sum (Y - b_1 X_1 - b_2 X_2 - \dots - b_m X_m) X_1 = 0 \\ \frac{\partial Q}{\partial b_2} = -2 \sum (Y - b_1 X_1 - b_2 X_2 - \dots - b_m X_m) X_2 = 0 \\ \vdots \\ \frac{\partial Q}{\partial b_m} = -2 \sum (Y - b_1 X_1 - b_2 X_2 - \dots - b_m X_m) X_m = 0 \end{cases}$$

- 整理后
$$\begin{cases} b_1 \sum X_1^2 + b_2 \sum X_1 X_2 + \dots + b_m \sum X_1 X_m = \sum X_1 Y \\ b_1 \sum X_1 X_2 + b_2 \sum X_2^2 + \dots + b_m \sum X_2 X_m = \sum X_2 Y \\ \vdots \\ b_1 \sum X_1 X_m + b_2 \sum X_2 X_m + \dots + b_m \sum X_m^2 = \sum X_m Y \end{cases}$$

2. 多元回归

- 多元线性回归方程系数求解
- 其中的 $X_1^2, X_1 X_2$ 分别为离均差乘积和SP, 离均差平方和SS, 可以直接计算

$$\begin{cases} b_1 SS_1 + b_2 SP_{12} + \cdots + b_m SP_{1m} = SP_{1y} \\ b_1 SP_{12} + b_2 SS_2 + \cdots + b_m SP_{2m} = SP_{2y} \\ \vdots \\ b_1 SP_{1m} + b_2 SP_{2m} + \cdots + b_m SS_m = SP_{my} \end{cases}$$



$$\begin{bmatrix} SS_1 & SP_{12} & \cdots & SP_{1m} \\ SP_{12} & SS_2 & \cdots & SP_{2m} \\ \vdots & & & \\ SP_{1m} & SP_{2m} & \cdots & SS_m \end{bmatrix} \times \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} SP_{1y} \\ SP_{2y} \\ \vdots \\ SP_{my} \end{bmatrix}$$

2. 多元回归

- 多元线性回归方程系数求解
- 求解偏回归系数变成了求解矩阵的形式

$$\begin{bmatrix} SS_1 & SP_{12} & \dots & SP_{1m} \\ SP_{12} & SS_2 & \dots & SP_{2m} \\ \vdots & & & \\ SP_{1m} & SP_{2m} & \dots & SS_m \end{bmatrix} \times \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} SP_{1y} \\ SP_{2y} \\ \vdots \\ SP_{my} \end{bmatrix}$$

$$Ab = K$$

$$A^{-1}Ab = A^{-1}K$$

$$b = A^{-1}K$$

2. 多元回归

- 多元线性回归方程系数求解
- 解出系数矩阵 A 的逆矩阵 A^{-1}
- 由 A^{-1} 求出 b_i 和 a

$$\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} SS_1 & SP_{12} & \dots & SP_{1m} \\ SP_{12} & SS_2 & \dots & SP_{2m} \\ \vdots & & & \\ SP_{1m} & SP_{2m} & \dots & SS_m \end{bmatrix}^{-1} \times \begin{bmatrix} SP_{1y} \\ SP_{2y} \\ \vdots \\ SP_{my} \end{bmatrix}$$

2. 多元回归

- 多元线性回归方程的假设检验
- 多元回归中的 y 的离均差平方和可以分解为离回归平方和 Q 与回归平方和 U

$$\begin{cases} SS_y = Q_y + U_y \\ U_y = b_1 SP_{1y} + b_2 SP_{2y} + \cdots + b_m SP_{my} \end{cases}$$

- Q 代表误差因素引起的平方和，也叫残差平方和
- U 代表由 x 变异引起 y 变异的平方和，也叫回归平方和

2. 多元回归

- 多元线性回归方程的假设检验
- 假设

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_m = 0$$

$$H_A : \beta_1, \beta_2, \dots, \beta_m \neq 0$$

- F检验 (df1=m, df2=n-m-1)

$$F = \frac{\frac{U_y}{m}}{\frac{Q_y}{n-m-1}}$$

2. 多元回归

- 多元线性回归方程的假设检验
- 应注意两个问题：
 - 多元线性回归关系显著不排斥有更合理的多元非线性回归方程存在
 - 多元线性回归显著不排斥其中存在着与因变量 y 无线性关系的自变量
- 因此：
 - 有必要对各个偏回归系数逐个进行假设检验
 - 只有当多元回归方程的偏回归系数均达到显著，多元回归的 F 值才有确定的意义

2. 多元回归

- 逐步回归 Stepwise regression
- 对于多变量资料，既包含对因变量 y 具有显著线性效应的自变量，又包含对 y 不具有显著线性效应的自变量
- 将不具有显著效应的自变量予以舍去，使所得到的多元线性回归方程中的自变量对因变量 y 均具有显著效应，这就是最优多元线性回归方程

2. 多元回归

- 逐步回归 Stepwise regression 从多元回归模型中取消一个自变量 x_i 后，总回归平方和减少的部分，称为自变量 x 对 y 的偏回归平方和，也就是 x 对 y 的回归贡献
 - 向后逐步回归
- I. 从 m 元回归分析开始，每步舍去一个不显著且偏回归平方和为最小的自变量
 - II. 每次舍去一个偏回归不显著且平方和最小的自变量之后，需对回归方程和各自变量重新进行假设检验
 - III. 直到回归方程所包含的自变量全部显著

3. 聚类分析 Clustering

- 在实际问题中，经常要将一些东西进行分类
- 分类问题：
 - 已知分类依据，将未知个体归属到已知分类中去（判别分析）
 - 事先不知道遇到的问题如何分类，需要选定一个统计量，建立一种合理的分类（聚类分析）
- 聚类分析的目的就是把相近或者相似的东西归成一类（相似元素集合）

3. 聚类分析 Clustering

- 根据对象不同，又分为R型和Q型聚类，但用到的方法基本一致
- R型列聚类：对数据矩阵的列（变量/特征）进行分类
 - 分析变量间的相似性，将性质相近的变量分组
 - 用途：降维、特征选择
- Q型行聚类：对数据矩阵的行（样本/个体）进行分类
 - 分析样本间的相似性，将特征相近的样本分组
 - 用途：样本分类、模式识别

3. 聚类分析

- 聚类分析的常用指标
- 聚类分析需要指标用于刻画各样品/变量间的相似/相近程度
- 常用指标包括距离系数和相似系数
- 不同的定量或者定性数据在进行聚类分析之前要进行数据变换
 - 消除数据自身特性（偏态，尺度不一）对聚类结果的干扰
 - 避免因数据本身的尺度、分布、量纲等问题导致错误的分组结果

3. 聚类分析

- 数据变换 (data transformation)
- 我们考察的p种变量一般都有不同量纲和取值范围, 为了使他们能放在一起比较, 需要提前进行变换
- 常用方法:
 - 中心化: $x' = x - \bar{x}$ (均值为0)
 - 标准化: $x' = \frac{x - \bar{x}}{s_x}$ (均值为0, 标准差为1)

3. 聚类分析

- 数据变换
- 常用方法：
 - 极差标准化: $x' = \frac{x - \bar{x}}{R_x}$ (均值为0, 极差为1)
 - 极差正规化: $x' = \frac{x - \min(x)}{R_x}$ ($0 \leq x' \leq 1$, 极差为1)
 - 对数化: $x' = \ln(x)$ (针对具有指数特征的右偏数据)

3. 聚类分析

- 并非所有场景都需要数据变换
 - 所有变量的尺度、量纲、方差完全一致
 - 聚类算法对尺度不敏感
 - 变量的尺度差异是故意保留的权重
- 多数聚类分析种必选的步骤，很多聚类中会默认对数据进行转换，除非修改设置

3. 聚类分析

- 距离系数
- 描述样本之间的亲疏程度就是距离
- 对于一个样本，
 - 如果用一个变量表示，可以在1维空间直线中定位
 - 有两个变量表示，可以在2维平面中定位
 - 有 p 个变量的话，可以是 p 维空间中的一个点
- 样本之间的远近就可以用 p 维空间中两个点的空间距离描述

3. 聚类分析

- 距离系数

- 例如以下计算样本 X_m 和 X_n 之间的距离，可以用 $d_{m,n}$ 表示

$$\begin{array}{c}
 \begin{array}{cccc}
 x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\
 x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\
 \vdots & \vdots & \vdots & \vdots \\
 \mathbf{X}_m & \boxed{x_{6,1} \quad x_{6,2} \quad \cdots \quad x_{6,p}} & & \\
 \vdots & \vdots & \vdots & \vdots \\
 \mathbf{X}_n & \boxed{x_{8,1} \quad x_{8,2} \quad \cdots \quad x_{8,p}} & & \\
 \vdots & \vdots & \vdots & \vdots \\
 x_{n,1} & x_{n,2} & \cdots & x_{n,p}
 \end{array}
 \end{array}$$

$d_{m,n}$

对于距离来说：

1. $d_{m,n} \geq 0$ (0代表没有距离)
2. $d_{m,n} = d_{n,m}$
3. $d_{m,n} \leq d_{m,k} + d_{k,n}$

3. 聚类分析

- 距离系数
- 对于定量变量，常用的距离系数
- 闵可夫斯基Minkowski距离

$$d_{m,n} = \left[\sum_{i=1}^p |x_{mi} - x_{ni}|^q \right]^{1/q}$$

- 当 $q=1$ 为绝对值距离， $q=2$ 为欧氏距离


3. 聚类分析

- 距离系数

- 欧氏距离 $d_{m,n} = \sqrt{[\sum_{i=1}^p |x_{mi} - x_{ni}|^2]}$

是聚类分析中比较广泛使用的距离

- 缺点是与变量的量纲有关，未考虑到各个变量之间的方差不同



3. 聚类分析

- 距离系数
- 例如以下三个身高体重样本, $d_{AB} = 6.4, d_{AC} = 34, d_{BC} = 30$
 - A: 65千克, 174厘米 (65000克, 1.74米)
 - B: 60千克, 170厘米 (60000克, 1.70米)
 - C: 65千克, 140厘米 (65000克, 1.40米)
- 从数据上看应该是A和B之间的身形数值更接近, 但是如果替换单位, 则 $d_{AB} = 5000, d_{AC} = 0.34, d_{BC} = 5000$


3. 聚类分析

- 距离系数
- 标准化欧氏距离

$$d_{m,n} = \sqrt{\left[\sum_{i=1}^p \left| \frac{x_{mi} - x_{ni}}{s_i} \right|^2 \right]}$$

3. 聚类分析

- 距离系数
- 马氏Mahalanobis距离
- 马氏距离是一种统计距离度量方法，用于计算某个点到分布中心的距离
- 点 p 与概率分布 D 之间的距离指的是点 p 的标准差与概率分布 D 的均值之间的偏离程度
- 如果点 P 位于概率分布的均值处，那么该距离为零





3. 聚类分析

- 距离系数
- 马氏距离的计算
- 对原始数据做了两次关键调整，把原始数据矫正成无尺度差异、无相关性的理想数据，再计算调整后数据的欧氏距离
- 数据调整：
 - 消除变量的尺度差异：数值差太多，会导致高值变量主导距离
 - 消除线性相关性：如果变量之间有线性相关（例如体重和bmi），那么欧氏距离会重复计算这部分


3. 聚类分析

- 距离系数
- 马氏距离的计算
- 第一步：中心化
- 第二步：去线性相关性，等方差化
- 第三步：用调整数据计算欧氏距离



3. 聚类分析

- 相似系数
- 之前的距离计算主要用于样本计算，变量之间主要用相似系数表示变量之间的亲疏程度
- 夹角余弦（余弦相似性）
- 两个向量有相同的指向时，余弦相似度的值为1；两个向量夹角为 90° 时，余弦相似度的值为0；两个向量指向完全相反的方向时，余弦相似度的值为-1





3. 聚类分析

- 相似系数
- 相关系数：就是 ρ ，也是标准化处理之后的余弦相似性
- 利用相似性计算变量之间的距离，也就是1-相似系数
- 相似度越小，距离越大。相似度越大，距离越小。


3. 聚类分析

- 系统聚类方法（层次聚类）
- 计算两两样本距离，得到距离矩阵
- 初始各个样本各自构成一类
- 合并类间最小距离的两个类为一个新类
- 计算新类与其他类的距离，得到新的距离矩阵
- 直到类的总个数为1
- 生成一个树状图dendrogram




3. 聚类分析

- 类间距离
- Single: 两个组合数据点中距离最近的两个数据点间的距离作为这两个组合数据点的距离
- Complete: 将两个组合数据点中距离最远的两个数据点间的距离作为这两个组合数据点的距离
- Average: 计算两个组合数据点中的每个数据点与其他所有数据点的距离然后平均




3. 聚类分析

- 系统聚类方法（层次聚类）
- 自上而下
- 自下而上




3. 聚类分析

- K-means 聚类
- 先预设k个中心centroid (随机选择)
- 通过距离选最近的中心组队
- 每次重新组队都更新中心，让每个中心内样本相似度最大、之间差异最大
- 最终形成k个中心




4. 主成分分析 Principal Component Analysis, PCA

- PCA是一种将高维数据转换为低维数据，同时尽可能保留信息的技术



原始的三维数据集，红色、蓝色、绿色箭头
分别代表第一、第二和第三主成分的方向



主成分分析 (PCA) 将三维数
据降维至二维后的散点图

4. 主成分分析 Principal Component Analysis, PCA

- 高维数据存在两个痛点：
 - 信息冗余：特征间可能高度相关，重复携带相同信息，增加计算成本；
 - 维度灾难：高维数据难以可视化，且后续建模（如聚类、判别分析）易受噪声干扰，导致效果变差
- PCA的解决方式：
 - 用少数几个主成分（虚拟特征）替代原始高维数据，这些虚拟特征能最大化保留原始数据的信息（方差），且相互独立无相关性
 - 既简化数据，又不丢失关键信息

4. 主成分分析 Principal Component Analysis, PCA



原始高维数据是一个倾斜的数据分布

我们要找一个“最佳拍摄角度”，也就是投影方向

使得照片里的特征最明显：方差更大，能看清数据的核心差异

同时第二个角度要和第一个垂直，这样两个角度的分布正交，避免重复信息


4. 主成分分析 Principal Component Analysis, PCA

- PCA 的核心准则有 3 个：
- 最大化方差：第一主成分（PC1）是原始数据的线性组合，其投影后的方差最大。方差越大，说明这个方向能反映数据的核心差异
- 正交性：后续的主成分（PC2、PC3...）必须与前面所有主成分正交，确保主成分间无相关性，消除冗余
- 顺序性：主成分按方差从大到小排序，前 k 个主成分的累计方差占比能覆盖原始数据的大部分信息，用这 k 个主成分替代原始数据，实现降维

4. 主成分分析 Principal Component Analysis, PCA

- 线性变换
- 1. 中心化
- 2. 计算协方差矩阵
 - 体现每个特征的方差（对角元素）和特征间的相关性（非对角元素）

4. 主成分分析 Principal Component Analysis, PCA



特征向量就是数据的核心分布方向

- 线性变换
- 3.对协方差矩阵做特征分解，求解特征值和特征向量，找到主成分轴
 - 特征向量 (Eigenvector)：对应主成分轴，每个特征向量是一个 p 维向量（和原始数据维度相同），代表一个主成分的方向
 - 特征值 (Eigenvalue)：对应每个特征向量的重要性，特征值越大，说明该主成分投影后的方差越大，携带的信息越多
 - PC1：特征值最大的特征向量；PC2；PC3...

4. 主成分分析 Principal Component Analysis, PCA

- 线性变换
- 4. 投影降维，得到低维数据
- 将中心化后的原始数据矩阵 X ，与前 k 个特征向量组成的矩阵 W 相乘，得到降维后的低维数据矩阵 Y

$$Y_{n \times k} = Z_{n \times p} \times W_{p \times k}$$

原始数据有 n 个样本、 p 个特征， W 是 p 维向量，保留 k 个主成分

最后得到的矩阵是 n 个样本， k 个主成分的低维矩阵

4. 主成分分析 Principal Component Analysis, PCA

- 方差解释率
- 最后用方差解释率判断降维保留多少主成分
- 累计方差解释率 = 前 k 个主成分的特征值之和 / 所有特征值之和
- 通常选择累计方差解释率 $\geq 80\% \sim 95\%$ 的最小 k 值, 既降维又能保留大部分信息


4. 主成分分析 Principal Component Analysis, PCA

- 假设我们有一组数据

Data =

x	y
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	3.0
2.3	2.7
2	1.6
1	1.1
1.5	1.6
1.1	0.9

原始数据散点图




4. 主成分分析 Principal Component Analysis, PCA

- 数据经过中心化

```
> mean_x <- mean(data$x)
> mean_y <- mean(data$y)
> data_centered <- data.frame(
  x = data$x - mean_x,
  y = data$y - mean_y)
```

	x	y
1	0.69	0.49
2	-1.31	-1.21
3	0.39	0.99
4	0.09	0.29
5	1.29	1.09
6	0.49	0.79
7	0.19	-0.31

中心化后的数据散点图



4. 主成分分析 Principal Component Analysis, PCA

- 计算特征值和特征向量

```
> cov_matrix <- cov(data_centered)
> eigen_result <- eigen(cov_matrix)
```

eigen() decomposition

\$values


[1] 1.2840277 0.0490834

\$vectors

	[,1]	[,2]
[1,]	0.6778734	-0.7351787
[2,]	0.7351787	0.6778734

第一主成分贡献率为 $1.284 / (1.284 + 0.049) = 0.963$

中心化数据与主成分方向




4. 主成分分析 Principal Component Analysis, PCA

- 用prcomp函数一键计算 PCA

```
> pca_result <- prcomp(data, center = TRUE,  
scale. = FALSE)  
> pc_scores <- pca_result$x  
pc_scores
```


	PC1	PC2
[1,]	-0.82797019	0.17511531
[2,]	1.77758033	-0.14285723
[3,]	-0.99219749	-0.38437499
[4,]	-0.27421042	-0.13041721
[5,]	-1.67580142	0.20949846
[6,]	-0.91294910	-0.17528244
[7,]	0.09910944	0.34982470

主成分得分散点图 (PC1 vs PC2)



4. 主成分分析 Principal Component Analysis, PCA

- 当前主流的主成分分析方法
- PCA, 线性的降维方法
- t-SNE, 非线性的降维方法
- UMAP,
- Diffusion maps



谢谢

