

《医学统计学八讲》课程讲义

王超

目录

1	速查表 Cheatsheet	2
2	概率与概率分布	2
2.1	由二项分布推导正态分布	2
3	假设检验	4
3.1	如何进行假设检验中的假设	4
3.2	第一、二类错误	5
3.3	显著性水平 α	5
4	回归分析	5
4.1	最小二乘法	6
4.2	回归	6
4.3	回归分析的方法	6
5	引言	6
6	字体和选项	7
7	R 代码段	7
8	源代码控	8
9	小结	8

1 速查表 Cheatsheet

离均差 (mean deviation): $\sum_{i=1}^n (x_i - \bar{x}) = 0$ [Sec.1]

离均差平方和 (sum of squares, SS): $\sum_{i=1}^n (x_i - \bar{x})^2$ [Sec.1]

方差, 均方 (variance, mean square, var): $\sigma^2 = \frac{\sum (x - \mu)^2}{N}$ [Sec.1]

标准差 (standard deviation, sd): $\sigma = \sqrt{\frac{\sum (x - \mu)^2}{N}}$ [Sec.1]

(样本均值的) 标准误 (standard error of mean, se): $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$ [Sec.3]

标准正态分布 (normal distribution) 的概率密度方程 (probability density function, PDF): $f(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2}$ [Sec.3]

标准正态离差 (standard deviate): $u = \frac{x - \mu}{\sigma}$ [Sec.3]

F 分布中的 F 值: $F = \frac{s_1^2}{s_2^2}$ [Sec.3]

t 分布中的 t 值: $t = \frac{\bar{x} - \mu}{s_{\bar{x}}} = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$ [Sec.3]

回归分析: [Sec.7]

离均差乘积和 (sum of product, SP): $SP = \sum (x - \bar{x})(y - \bar{y})$

回归平方和: $U = \sum_1^n (\hat{y} - \bar{y})^2$

残差平方和, 离回归平方和: $Q = \sum_1^n (y - \hat{y})^2$

残差, 回归估计误差 (residual): $\epsilon_i = y_i - \hat{y}_i$

离回归方差: $s_{y/x}^2 = \frac{Q}{df}$, 直线回归中 $df = n - 2$

离回归标准差, 直线回归估计标准误: $s_{y/x} = \sqrt{\frac{Q}{n-2}}$

2 概率与概率分布

2.1 由二项分布推导正态分布

正态分布是自然科学与行为科学中的定量现象的一个方便模型。各种各样的心理学测试分数和物理现象比如光子计数都被发现近似地服从正态分布。尽管这些现象的根本原因经常是未知的, 理论上可以证明如果把许多小作用加起来看做一个变量, 那么这个变量服从正态分布 (在 R.N.Bracewell 的 Fourier transform and its application 中可以找到一种简单的证明)。正态分布出现在许多区域统计: 例如, 采样分布均值是近似地正态的, 即使被采样的样本的原始群体分布并不服从正态分布。另外, 正态分布信息熵在所有的已知均值及方差的分布中最大, 这使得它作为一种均值以及方差已知的分布的自然选择。正态分布是在统计以及许多统计测试中最广泛应用的一类分布。在概率论, 正态分布是几种连续以及离散分布的极限分布。

正态分布最早是棣莫弗在 1718 年著作的书籍的 (Doctrine of Chance), 及 1734 年发表的一篇关于二项分布文章中提出的, 当二项随机变量的位置参数 n 很大及形状参数 p 为 $1/2$ 时, 则所推导出二项分布的近似分布函数就是正态分布。拉普拉斯在 1812 年发表的《分析概率论》(Theorie Analytique des Probabilites) 中对棣莫弗的结论作了扩展到二项分布的位置参数为 n 及形状参数为 $1 > p > 0$ 时。现在这一结论通常被称为棣莫弗—拉普拉斯定理。拉普拉斯在误差分析试验中使用了正态分布。勒让德于 1805 年引入最小二乘法这一重要方法; 而高斯则宣称他早在 1794 年就使用了该方法, 并通过假设误差服从正态分布给出了严格的证明。将正态分布称作“钟形曲线”的习惯可以追溯到 Jouffret 他在 1872 年首次提出这个术语 (Bell curve) 用来指代二元正态分布。正态分布这个名字还被查尔斯·皮尔士、法兰西斯·高尔顿、威尔赫姆·莱克希斯在 1875 分别独立地使用。这个术语是不幸的, 因为它反映和鼓励了一种谬误, 即很多概率分布都是正态的。这个分布被称为“正态”或者“高斯”正好是史蒂格勒名字由来法则的一个例子, 这个法则说“没有科学发现是以它最初的发现者命名的”。

当二项随机变数的位置参数 n 很大及形状参数 p 为 $1/2$ 时, 则所推导出二项分布的近似分布函数就是正态分布。当然这个其实就是个极限问题, 有兴趣之后我们可以具体讨论。但是这个结果确实是我们直观上可以相像的, 当然你还是无法想像, 那我们来看看这个计算机的模拟试验。

我们的 $R3, R4, R5$ 分别是 $N=100, 1000, 10000$ 次二项分布中生成的, 清晰的看到随着 N 的增加, 这个分布越来越接近我们这个具有代表性的这个正态分布了。

事实上, 这个东西的严格的讲还有特别厉害的名字, 中心极限定理, 中心极限定理有着有趣的历史。这个定理的第一版被 法国 数学家 棣莫弗发现, 他在 1733 年发表的卓越论文中使用 正态分布去估计大量抛掷硬币出现正面次数的分布。这个超越时代的成果险些被历史遗忘, 所幸著名法国数学家 拉普拉斯在 1812 年发表的巨著 *Théorie Analytique des Probabilités* 中拯救了这个默默无闻的理论。拉普拉斯扩展了 棣莫弗的理论, 指出二项分布可用正态分布逼近。但同 棣莫弗一样, 拉普拉斯的发现在当时并未引起很大反响。直到十九世纪末中心极限定理的重要性才被世人所知。1901 年, 俄国数学家 里雅普诺夫用更普通的随机变量定义中心极限定理并在数学上进行了精确的证明。如今, 中心极限定理被认为是 (非正式地) 概率论中的首席定理。

然而，正态分布真正走入人们视线的并不是由这个无聊的投硬币试验所得的二项分布的逼近，而是实实在在的工程误差分析中应用。据说 wiki 说，拉普拉斯在 误差分析试验中使用了正态分布。勒让德于 1805 年引入 最小二乘法这一重要方法；而 高斯则宣称他早在 1794 年就使用了该方法，并通过假设误差服从正态分布给出了严格的证明。

之前我们说到高斯对测量误差研究中发现了正态分布，并且这项研究也成为了当代统计学中重要的思想—最大似然发现的源头。下面我们来仔细看看，他是如何导出这个完美的分布的。

首先我们要解释几个概念，第一个是似然（Likelihood）。什么是似然，简单通俗的来讲就是，一系列的概率密度函数的乘积，说白了也就是还是一种特别的复合的“概率”。比如对于正态分布，如果有独立同分布的观察值 $x_1, x_2, \dots, x_n$ ，则其的似然为：

3 假设检验

在现实中，例如进行流行病学调查时，经常会遇到对一个总体数据进行评估的问题。我们无法直接统计全部数据，这就需要从总体中抽出一部分样本，通过样本来估计总体情况。举一个例子，我们想知道某个地区的中老年人群血压情况，我们需要对总体进行评估。但是并不是全部人群都可以调查到，中老年人群总体是动态变化的，我们无法对总体进行评估。我们只能从总体的用户随机抽取样本进行分析，用样本数据来充当总体数据表现，以此来评估中老年人群的血压情况。

3.1 如何进行假设检验中的假设

假设检验是先对总体参数提出一个假设值，然后利用样本信息判断这一假设是否成立

由定义可知，我们需要对结果进行假设，然后拿样本数据去验证这个假设。

所以做假设检验时会设置两个假设：

一种叫原假设，也叫零假设，用 H_0 表示。原假设一般是统计者想要拒绝的假设。原假设的设置一般为：等于 $=$ 、大于等于 $\geq$ 、小于等于 $\leq$ 。

另外一种叫备择假设，用 H_1 表示。备则假设是统计者想要接受的假设。备择假设的设置一般为：不等于、大于 $>$ 、小于 $<$ 。

例子在进行假设检验时，我们希望接受版本 2 的假设，想拒绝接受版本 1 的假设。所以我们的假设设置为： H_0 ：版本 1 $\geq$ 版本 2， H_1 ：版本 1 $<$ 版本 2。

为什么统计者想要拒绝的假设放在原假设呢？因为原假设被拒绝如果出错的话，只能犯第 I 类错误，而犯第 I 类错误的概率已经被规定的显著性水平所控制。有点看不懂哈？没关系我们讲一下假设检验中的两种错误和显著性水平就清楚了。

3.2 第一、二类错误

我们通过样本数据来判断总体参数的假设是否成立，但样本是随机的，因而有可能出现小概率的错误。这种错误分两种，一种是弃真错误，另一种是取伪错误。

弃真错误也叫第 I 类错误或 α 错误：它是指原假设实际上是真的，但通过样本估计总体后，拒绝了原假设。明显这是错误的，我们拒绝了真实的原假设，所以叫弃真错误，这个错误的概率我们记为 α 。这个值也是显著性水平，在假设检验之前我们会规定这个概率的大小。

取伪错误也叫第 II 类错误或 β 错误：它是指原假设实际上假的，但通过样本估计总体后，接受了原假设。明显是错的，我们接受的原假设实际上是假的，所以叫取伪错误，这个错误的概率我们记为 β 。

现在清楚原假设一般都是想要拒绝的假设了么？因为原假设被拒绝，如果出错的话，只能犯弃真错误，而犯弃真错误的概率已经被规定的显著性水平所控制了。这样对统计者来说更容易控制，将错误影响降到最小。

3.3 显著性水平 α

4 回归分析

回归分析是一种统计学上分析数据的方法，目的在于了解两个或多个变数间是否相关、相关方向与强度，并建立数学模型以便观察特定变数来预测研究者感兴趣的变数。更具体的来说，回归分析在于找到一条能够代表所有观测资料的函数曲线，用该函数代表因变数和自变量之间的关系。一般来说，通过回归分析我们可以由给出的自变量估计因变量的条件期望。

回归的最早形式是最小二乘法，由 1805 年的勒让德 (Legendre) [1] 和

1809 年的高斯 (Gauss) [2] 出版。勒让德和高斯都将该方法应用于从天文观测中确定关于太阳的物体的轨道 (主要是彗星, 但后来是新发现的小行星) 的问题。高斯在 1821 年发表了最小二乘理论的进一步发展 [3], 包括高斯-马尔可夫定理的一个版本。

4.1 最小二乘法

高斯如何计算谷神星运行轨道并作出预测呢? 其实就是使用最小二乘法拟合了轨迹 (天体运动论, 1809)。假定下图是皮亚齐观测到的从 0 时到 10 时的谷神星观测记录, 每个点上的横坐标表示观测时间, 纵坐标表示谷神星的位置, 我们有一条曲线非常接近地经过上图的一系列观测点, 主要找到这条曲线的方程 $f(x)$

4.2 回归

“回归”一词最早由法兰西斯·高尔顿 (Francis Galton) 所使用 [4][5]。他曾对亲子间的身高做研究, 发现父母的身高虽然会遗传给子女, 但子女的身高却有逐渐“回归到中等 (即人的平均值)”的现象。不过当时的回归和现在的回归在意义上已不尽相同。

4.3 回归分析的方法

4.3.1 动差估计 (Method of Moment; MOM)

4.3.2 最小二乘法 (Ordinary Least Square Estimation; OLSE)

4.3.3 最大似然估计 (Maximum Likelihood Estimation; MLE)

5 引言

中文 LaTeX 文档并非难题。当然这句话得站在巨人 CTeX 的肩膀上才能说, 它让我们只需要一句

```
\documentclass{ctexart} % 或者 ctexrep/ctexbook
```

或者

```
\usepackage{ctex}
```

就轻松搞定中文 LaTeX 排版问题。

6 字体和选项

LaTeX 包 `ctex` 支持若干种字体选项，如果你是 `ctex` 老用户，请注意这里我们要求的最低版本是 2.2，你可能需要升级你的 LaTeX 包。从版本 2.0 开始，`ctex` 支持根据不同操作系统自动选择中文字体，简直是为人类进步作出了巨大贡献，我们再也不必费尽口舌向用户解释“啊，你用 Windows 啊，那么你该使用什么字体；啊，你用 Mac 啊，又该如何如何”。

下面的 YAML 元数据应该能满足多数用户的需求，主要设置两项参数：文档类为 `ctexart`（当然也可以是别的类），输出格式为 `rticles::ctex`，其默认 LaTeX 引擎为 XeLaTeX（真的，别纠结你的旧爱 PDFLaTeX 了）。

```
---
documentclass: ctexart
output: rticles::ctex
---
```

`rticles::ctex` 的参数都是普通的 `pdf_document` 参数，参见文档 `rmarkdown` 包的文档，这里就不赘述了。

Windows 和 Mac 用户应该都已经有了自带的中文字体了。Linux 用户可以考虑 Fandol 字体，它号称是免费的，不过我们也没太搞清楚它的来头。如果你不想操心这些问题，我们强烈建议你卸载你当前的 LaTeX 套装（TeX Live 或 MiKTeX 或 MacTeX），换上 TinyTeX，一切将会自动化搞定。

```
devtools::install_github(c('rstudio/rmarkdown', 'yihui/tinytex'))
tinytex::install_tinytex()
```

7 R 代码段

R 代码用 R Markdown 的语法嵌入，即三个反引号开始一段代码 ````\{r\}` 和三个反引号 ````` 结束一段代码：

```
options(digits = 4)
fit = lm(dist ~ speed, data = cars)
coef(summary(fit))

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -17.579      6.7584  -2.601 1.232e-02
## speed          3.932      0.4155   9.464 1.490e-12

b = coef(fit)
```

上面回归方程中的斜率是 3.9324，完整的回归方程为：

$$Y = -17.5791 + 3.9324x$$

画图当然也是木有问题的啦，想画就说嘛，不说我怎么知道你想画呢？

```
par(mar = c(4, 4, .1, .1), las = 1)
plot(cars, pch = 19)
abline(fit, col = 'red')
```

请不要问我为什么图浮动到下一页去了，这么初级的 LaTeX 问题问出来信不信我扁你。

8 源代码控

这里提供的 rticles 模板可能由于种种原因不能满足客官的要求，LaTeX 用户就是这样无止境地调格式（唉，跟 Word 用户到底有啥区别呢）。若真是需要调整，你可以复制一份默认模板去改。默认模板来自 Pandoc: <https://github.com/jgm/pandoc/blob/master/data/templates/default.latex> 它是一个文本文件。若熟悉 LaTeX 的话一看就明白，只不过里面有些 Pandoc 变量而已；若不熟悉 LaTeX 我们在这里说了也白说，花几天时间好好啃一啃 LaTeX 入门手册吧。

9 小结

事实证明我们可以理直气壮地通过 XeLaTeX 将中文 R Markdown 转化为 PDF 文档，麻麻再也不用担心我的论文满屏幕都是反斜杠，朕养完




图 1: cars 数据散点图以及回归直线。

小白鼠之后终于不必先折腾三个小时 LaTeX 再开始写实验报告了：打开 RStudio，菜单 File > New File > R Markdown，然后从模板中选择 CTeX Documents，搞定。

- [1] A. M. Legendre, *Nouvelles méthodes pour la détermination des orbites des comètes*. Paris : F. Didot, an 13, 1805.
- [2] C. F. Gauss, “Theoria Motus Corporum Coelestium,” Berlin, Heidelberg: Springer Berlin Heidelberg, 1981. doi: 10.1007/978-3-642-92478-1.